RÉPUBLIQUE ISLAMIQUE DE MAURITANIE

Honneur · Fraternité · Justice

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université de Nouakchott

كلية العلوم و التقنيات
FACULTÉ DES SCIENCES ET TECHNIQUES

Unité de Recherche Al-Khawarizmi

DÉPARTEMENT D'INFORMATIQUE

MÉMOIRE DE FIN D'ÉTUDES

En vue de l'obtention du diplôme de

Master Informatique · Mention Intelligence Artificielle

Parcours : Machine Learning & Data Science (MLDS)

Vers une Reconnaissance Sémantique de la Langue des Signes Arabe : fusion multimodale (mains, visage, posture) et structuration ontologique du signe

PRÉSENTÉ PAR

Mekfoule Sidi Moctar El Bechir

Matricule : C30859

EFFECTUÉ AU SEIN DE

Unité de Recherche Al-Khawarizmi (*AI for Optimization and Digital Innovation in Various Fields*), FST, Université de Nouakchott

Stage du 02/05/2026 au 02/09/2026

ENCADRANT ACADÉMIQUE

Pr. Mohamedade Farouk Nanne

DEVANT LE JURY COMPOSÉ DE

RÔLE	NOM	GRADE ET ÉTABLISSEMENT
Président	Pr. Mohamed Lamine DIAKITÉ	FST, Université de Nouakchott
Rapporteur	Pr. Abdelmounaim ABDALI	Univ. Cadi Ayyad, Marrakech (visio)
Encadrant académique	Pr. Mohamedade Farouk Nanne	Professeur (PES), FST

Soutenu le 24/10/2026 **Nouakchott, Mauritanie** **Année universitaire 2025–2026**

Contributions et réalisations hors stage

Ces pages valorisent ce que l'étudiant a produit ou obtenu pendant le Master en dehors du stage. Chaque ligne renvoie à une preuve placée en annexe F.

1. Certificats, formations et événements scientifiques

Conférences, écoles d'été (*summer schools*), ateliers, MOOC, certifications professionnelles.

Intitulé	**Organisateur**	**Lieu**	**Date**	**Durée**
École d'été LLMs et langues nationales, 1re édition (grands modèles de langage appliqués aux langues mauritaniennes peu dotées)	Université de Nouakchott, avec l'appui de la coopération allemande (GIZ)	Nouadhibou	23–30/08/2026	8 jours

2. Publications scientifiques

Articles de revue, communications, posters, preprints, jeux de données ou logiciels publiés. Statut : publié, accepté, soumis ou en préparation.

Référence complète	**Type**	**Statut**	**Rôle**	**DOI / lien**
M. S. M. El Bechir, O. M. A. Deddah, C. A. A. Telmoud, M. C. Tourad et M. F. Nanne, *Towards Semantic Recognition of Arabic Sign Language : Multimodal Fusion and Ontological Structuring*, International Conference I2COMSAPP'26, 2026.	Conférence	Accepté	1er auteur	En cours de publication

3. Prototype et MVP

Projet	Description	Technologies	Stade	Lien
Système ARSL multimodal	Reconnaît 7 expressions conversationnelles de la Langue des Signes Arabe Unifiée à partir d'une vidéo (97,1 % d'accuracy sur le jeu de test) et renvoie le signe avec sa description phonologique grâce à une ontologie OWL. Destiné à la recherche et à la démonstration.	Python, TensorFlow/Keras, MediaPipe, rdflib, Protégé, Streamlit	Prototype de recherche	GitHub – SignLanguageProject

4. Projets en préparation

Dans le prolongement de ce travail, les développements suivants sont envisagés (voir la conclusion générale) :

- **Application mobile :** exploiter la légèreté du modèle (149K paramètres) pour une application embarquée destinée à la communauté sourde.
- **Extension du corpus :** passer de 7 à 50 signes ou plus, puis à la langue des signes continue.
- **Validation avancée :** évaluation inter-signeurs (*Leave-One-Signer-Out*) et plusieurs graines aléatoires.
- **Couplage neuro-symbolique :** utiliser l'ontologie pendant l'apprentissage et l'inférence.

Ces projets sont au stade de perspectives : aucun n'a encore été réalisé.

5. Autres réalisations

- Stage de recherche à l'Unité de Recherche Al-Khawarizmi (02/05/2026 – 02/09/2026), sous l'encadrement du Pr. Mohamedade Farouk Nanne.
- Constitution d'un corpus original de 356 séquences de la Langue des Signes Arabe Unifiée (dix enfants sourds), validé par un enseignant sourd expert.
- Conception d'une ontologie OWL phonologique de la Langue des Signes Arabe Unifiée (Protégé).

Dédicaces

Je dédie ce travail en signe de reconnaissance.

◇

À celui qui a lutté et s'est sacrifié pour m'offrir les conditions propices à ma réussite :

Mon très cher père,

SID' EL MOCTAR EL BECHIR

◇

À celle qui m'a couverte de tendresse et d'affection
et qui a constitué la première école de mon existence :

À la mémoire de ma très précieuse, chaleureuse et aimable mère,

ROKHAYA HAMADY

Ton âme si belle s'est envolée vers le paradis. Il me reste la douceur de tes sourires, l'éclat de ton visage et les précieux souvenirs de toi, qui sont une source de bonheur. Je t'aime tellement… Tu me manques à chaque instant. Rien de tout cela n'aurait été possible sans ton sacrifice. Que Dieu ait pitié de toi, maman, et t'accorde Sa miséricorde. ♥

Grâce à mes parents, j'ai pu faire mes études et gravir
les pentes qui me semblaient infranchissables.

◇

À ma grand-mère maternelle,

MAKFOULLA EL HACEN

◇

À mon très cher frère,

HAMOUDY HAMADY

Mon grand frère maternel, mon compagnon de cœur et l'un des êtres qui m'est le plus cher. À toi qui as toujours été si proche de moi, avec ta tendresse, ta bienveillance et ton affection. Ta présence dans ma vie est un véritable cadeau. Je te dédie une pensée particulière, avec tout mon amour, ma reconnaissance et ma profonde affection.

◇

À mes frères et mes sœurs,
À toute personne qui s'est sacrifiée pour m'offrir les conditions propices à ma réussite.

◇

À TOUTE LA COMMUNAUTÉ SOURDE

Je tiens à exprimer ma profonde gratitude à l'ensemble de la communauté sourde, qui m'a accueillie avec bienveillance et m'a permis de mieux comprendre la richesse de la langue des signes, ainsi que les réalités et les défis vécus au quotidien par les personnes sourdes.

◇

Que ce travail soit l'expression de ma grande affection
et un témoignage de mon attachement et de mon profond amour.

Remerciements

Mes remerciements s'adressent tout d'abord à mon encadrant académique, le **Professeur Mohamedade Farouk Nanne**, pour sa disponibilité, ses conseils avisés et la rigueur scientifique qu'il m'a transmise tout au long de la réalisation de ce mémoire de Master.

Je tiens également à remercier l'**Unité de Recherche Al-Khawarizmi** (*AI for Optimization and Digital Innovation in Various Fields*) pour m'avoir accueillie dans le cadre de mon stage de recherche et pour le cadre scientifique offert durant la réalisation de ce travail.

Je tiens à exprimer ma profonde gratitude envers l'ensemble des enseignants et du corps professoral du Master Intelligence Artificielle (spécialité MLDS) de la Faculté des Sciences et Techniques de l'Université de Nouakchott, pour la qualité de la formation dispensée.

Mes remerciements vont aussi aux membres du jury qui ont accepté d'évaluer ce travail et d'apporter leurs remarques constructives pour son amélioration.

Enfin, je remercie sincèrement toutes les personnes et les membres de la communauté qui ont contribué, de près ou de loin, à la constitution et à la collecte des données pour le corpus de la Langue des Signes Arabe Unifiée (U-ArSL).

Résumé

La reconnaissance automatique de la langue des signes repose traditionnellement sur la classification statistique de gestes manuels, réduisant souvent le signe à une simple étiquette lexicale sans modélisation de sa structure linguistique. Ce mémoire présente une approche hybride pour la reconnaissance de la Langue des Signes Arabe Unifiée (U-ArSL), appliquée au contexte mauritanien : le système reconnaît d'abord un signe (classification), puis lui associe, grâce à une ontologie OWL, une description phonologique et sémantique. Il ne réalise donc pas directement une reconnaissance sémantique.

Le système proposé combine une extraction de points de repère squelettiques (*landmarks*) via MediaPipe Holistic (mains, visage et posture) avec une architecture de réseaux de neurones récurrents bidirectionnels à mécanisme d'attention (BiLSTM + Attention). Afin d'évaluer l'intégration optimale des signaux visuels, nous comparons les stratégies de fusion précoce (*Early Fusion*) et tardive (*Late Fusion*). Les résultats expérimentaux, obtenus sur un corpus restreint (35 séquences de test, évaluation intra-signeur), indiquent un avantage de la fusion tardive multimodale, avec une précision globale de **97,1 %** sur le jeu de test, contre **54,3 %** pour un modèle centré uniquement sur les mains. De plus, les prédictions statistiques sont couplées à une ontologie linguistique en OWL (*Web Ontology Language*), permettant d'enrichir chaque signe reconnu par ses caractéristiques phonologiques (forme de la main, emplacement, mouvement, orientation et expressions faciales) et d'appuyer l'analyse des erreurs ; l'ontologie est interrogée après la classification et n'influence pas la prédiction.

Mots-clés : Langue des Signes Arabe (ArSL), Vision par ordinateur, Fusion multimodale, BiLSTM, Mécanisme d'attention, Ontologie OWL, IA hybride.

Abstract

Automatic Sign Language Recognition (SLR) traditionally relies on statistical classification of manual gestures, often reducing a sign to a plain lexical label without modeling its underlying linguistic structure. This thesis presents a hybrid approach for the recognition of Unified Arabic Sign Language (U-ArSL), tailored to the Mauritanian context: the system first recognizes a sign (classification), then attaches a phonological and semantic description to it through an OWL ontology. It therefore does not perform semantic recognition directly.

The proposed architecture combines skeletal landmark extraction via MediaPipe Holistic (covering hands, face, and body pose) with a Bidirectional Long Short-Term Memory network enhanced by an Attention Mechanism (BiLSTM + Attention). To determine the optimal integration of visual modalities, early and late fusion strategies are compared. Experimental results, obtained on a small corpus (35 test sequences, intra-signer evaluation), indicate an advantage of multimodal late fusion, with an overall test accuracy of **97.1%**, compared to **54.3%** for a hands-only baseline model. Furthermore, the predicted sign is linked, after classification, to a formal OWL (Web Ontology Language) phonological ontology that provides its structural phonological parameters (handshape, location, movement, orientation, and facial expressions) and supports error analysis; the ontology does not influence the prediction.

Keywords: Arabic Sign Language (ArSL), Computer Vision, Multimodal Fusion, BiLSTM, Attention Mechanism, OWL Ontology, Hybrid AI.

الملخص

يعتمد التعرّف الآلي على لغة الإشارة تقليدياً على التصنيف الإحصائي للإيماءات اليدوية، مما يختزل الإشارة غالباً في مجرد وسم معجمي دون نمذجة بنيتها اللغوية. تقدّم هذه المذكرة مقاربة هجينة للتعرّف على لغة الإشارة العربية الموحّدة (U-ArSL) في السياق الموريتاني: يتعرّف النظام أولاً على الإشارة (تصنيف)، ثم يربطها بوصف فونولوجي ودلالي عبر أنطولوجيا OWL، فهو لا يُجري تعرّفاً دلالياً مباشراً.

يجمع النظام المقترح بين استخراج نقاط المعالم الهيكلية (landmarks) عبر MediaPipe Holistic (اليدان والوجه والوضعية الجسدية) وبنية شبكات عصبية تكرارية ثنائية الاتجاه ذات آلية انتباه (BiLSTM + Attention). ولتقييم الدمج الأمثل للإشارات البصرية، قارنّا استراتيجيتي الدمج المبكر (Early Fusion) والدمج المتأخر (Late Fusion). وتشير النتائج التجريبية، المحصلة على مجموعة بيانات صغيرة (35 تسلسلاً للاختبار، ومن المشاركين أنفسهم في التدريب والاختبار)، إلى أفضلية الدمج المتأخر متعدد الوسائط، إذ بلغت الدقة الإجمالية 97.1% على مجموعة الاختبار، مقابل 54.3% لنموذج يعتمد على اليدين فقط. إضافةً إلى ذلك، تُربط الإشارة المتوقّعة بعد التصنيف بأنطولوجيا لغوية بلغة OWL (Web Ontology Language)، مما يتيح إثراءها بخصائصها الفونولوجية (شكل اليد، الموضع، الحركة، الاتجاه، وتعابير الوجه) ودعم تحليل الأخطاء، دون أن تؤثر الأنطولوجيا في التنبؤ.

الكلمات المفتاحية: لغة الإشارة العربية (ArSL)، الرؤية الحاسوبية، الدمج متعدد الوسائط، المقاربة الهجينة، OWL، آلية الانتباه، أنطولوجيا BiLSTM.

Table des matières

Contributions et réalisations hors stage ii

Dédicaces iv

Remerciements v

Résumé vi

Abstract vii

Liste des abréviations xv

Introduction générale 1

1 Contexte du projet et organisme d'accueil 3

1.1 Présentation de l'organisme d'accueil . . . 3

1.1.1 L'Unité de Recherche Al-Khawarizmi . . . 3

1.1.2 Cadre du stage . . . 3

1.1.3 Travail de terrain . . . 4

1.2 Contexte et problématique . . . 4

1.2.1 Contexte général . . . 4

1.2.2 Problématique et motivation . . . 5

1.2.3 Note sur la terminologie . . . 6

1.3 Cahier des charges . . . 6

1.3.1 Spécifications fonctionnelles . . . 7

1.3.2 Exigences techniques et contraintes . . . 7

1.3.3 Cadre expérimental et contraintes de l'étude . . . 8

1.3.4 Considérations éthiques et périmètre du projet . . . 8

1.3.5 Délimitation du champ d'étude et hiérarchisation des travaux . . . 9

1.4 Objectifs et périmètre . . . 10

1.4.1 Objectif général . . . 10

1.4.2 Objectifs spécifiques . . . 10

1.4.3 Questions de recherche et hypothèses . . . 11

1.4.4 Contributions du travail . . . 12

1.5 Planification . . . 13

1.6 Conclusion du chapitre . . . 13

2 État de l'art **14**
2.1 Problématique de la Langue des Signes Arabe 14
2.1.1 La nature visuo-gestuelle et tridimensionnelle du signe 14
2.1.2 La réduction du signe à une étiquette lexicale brute 15
2.1.3 L'absence d'annotations phonologiques dans les jeux de données 15
2.1.4 Le morcellement dialectal et l'absence de standardisation 16
2.1.5 L'arrêt à la reconnaissance statistique sans compréhension sémantique . 16
2.2 Approches existantes pour la reconnaissance des langues des signes 16
2.2.1 Approches basées sur la vision directe vs. capteurs physiques 17
2.2.2 Modélisation temporelle et architectures profondes multimodales . . . 17
2.2.3 Extraction de repères squelettiques (*Keypoints/Landmarks*) 18
2.3 Approches multimodales et fusion d'informations 18
2.3.1 Modalités manuelles vs. non-manuelles 19
2.3.2 Taxonomie des stratégies de fusion (*Early, Late, Hybrid*) 19
2.4 De la représentation sémantique à l'ingénierie des connaissances : Fondements et limites des modèles symboliques 20
2.4.1 Panorama exhaustif des formalismes de représentation du sens 20
2.4.2 Limites des représentations classiques 21
2.4.3 L'émergence du Web Sémantique : De la donnée brute au sens formel . 21
2.4.4 Synthèse : L'Ontologie OWL comme aboutissement pour l'IA Neuro-Symbolique 22
2.5 L'Ontologie appliquée aux Langues des Signes 22
2.5.1 Declerck et al. — La référence fondatrice 22
2.5.2 Elsayed & Fathy — L'approche lexicale pour l'ArSL 23
2.5.3 Clarification méthodologique et positionnement de notre contribution . 24
2.5.4 Limites identifiées dans la littérature consultée 25

3 Analyse, méthodologie et conception **27**
3.1 Analyse des besoins 27
3.2 Données et collecte sur le terrain 27
3.2.1 Constitution du corpus et distribution des classes 27
3.3 Choix méthodologiques et technologiques 28
3.3.1 Pourquoi MediaPipe Holistic ? 29
3.3.2 Pourquoi BiLSTM avec Attention ? 30
3.3.3 Pourquoi Late Fusion ? 31
3.3.4 Pourquoi TensorFlow/Keras avec Python ? 32
3.3.5 Cohérence globale et matrice de justification des choix d'architecture . 33
3.4 Architecture de la solution 33
3.4.1 Architecture globale du système 34

3.4.2 Spécialisation des branches multimodales 35
3.4.3 Mécanisme d'attention et BiLSTM 36
3.4.4 Fusion tardive (Late Fusion) et décision 36
3.4.5 Modélisation ontologique en OWL 36
3.5 Conclusion du chapitre 38

4 Réalisation et protocole expérimental 39
4.1 Environnement de travail 39
4.2 Mise en œuvre des données 39
4.2.1 Prétraitement et normalisation des landmarks 39
4.2.2 Harmonisation temporelle (padding et masquage) 39
4.2.3 Découpage et protocole d'évaluation 39
4.3 Implémentation des modèles 40
4.3.1 Intégration de la couche sémantique (ontologie) 41
4.4 Protocole expérimental 42
4.5 Déploiement 42
4.6 Difficultés rencontrées 42

5 Résultats et discussion 43
5.1 Modèle retenu : Holistic + Late Fusion + Attention (Exp1) 43
5.1.1 Performances globales du modèle Exp1 43
5.1.2 Performances détaillées par classe gestuelle 44
5.2 Études d'ablation 44
5.2.1 Apport de la Multimodalité Holistique (Exp3— Test de H1) 45
5.2.2 Évaluation de la Stratégie de Fusion (Exp2 — Test de H2) 45
5.2.3 Analyse par Typologie des Signes (Test de H3) 45
5.2.4 Rôle de l'Explicabilité Temporelle et de l'Attention (Exp4 — Test de H4) 46
5.3 Hiérarchie d'impact des facteurs d'architecture 46
5.4 Évaluation de la Robustesse Architecturale — Comparaison Phase 1 vs Phase 2 (Test de H5) 47
5.5 Analyse de l'Erreur de Classification (Couplage Neuro-Symbolique) 47
5.5.1 Explication phonologique et ontologique (Couche Symbolique) 47
5.5.2 Explication technique et post-hoc (Pipeline de Données) 48
5.6 Synthèse des résultats et statut des hypothèses 48
5.7 Discussion 49
5.7.1 Synthèse au regard des hypothèses 49
5.7.2 Fusion multimodale : contribution et comparaison des stratégies 49
5.7.3 Contribution du mécanisme d'Attention 50
5.7.4 Contribution des différentes modalités 50
5.7.5 Apport de la couche sémantique et de l'ontologie 50

5.7.6 Analyse du comportement d'apprentissage 51
5.7.7 Discussion des résultats par rapport aux travaux existants 52
5.8 Limites, biais et éthique 53
5.8.1 Taille et diversité du corpus 53
5.8.2 Troncature et padding des séquences 53
5.8.3 Validation limitée (signeurs et variabilité des seeds) 53
5.8.4 Degré de couplage entre modèle neuronal et ontologie 53
5.9 Conclusion du chapitre 54

Conclusion générale et perspectives **55**

Bibliographie **57**

A Extraits de code commentés et lien vers le dépôt **60**

B Détails du jeu de données **61**
B.1 Protocole d'enregistrement 61
B.2 Modèle de formulaire de consentement 62
B.3 Autorisation de l'établissement 64

C Hyperparamètres et résultats complets **67**
C.1 Model Card 67
C.2 Environnement technique 67
C.3 Configuration expérimentale 68
C.3.1 Environnement matériel 68
C.3.2 Environnement logiciel 68
C.3.3 Organisation du projet et reproductibilité 68
C.4 Matrices de confusion 69
C.5 Rapports de classification 69
C.6 Courbes d'apprentissage 72

D Maquettes, diagrammes et captures d'écran **73**
D.1 Structure de l'ontologie 73
D.1.1 Hiérarchie des classes 73
D.1.2 Propriétés 73
D.1.3 Exemple d'individu : Sign_ThankYou 74

E Article soumis ou publié (le cas échéant) **75**

F Preuves des contributions hors stage **76**

Table des figures

2.1 Pile technologique du Web sémantique (RDF, RDFS, OWL, SPARQL) ancrée sur les prédictions numériques du modèle neuro-symbolique. 24

3.1 Pipeline du système de reconnaissance ArSL multimodal. 35

5.1 Ordre d'impact des facteurs étudiés : écart d'accuracy par rapport à Exp1 lorsque le facteur est retiré (ordre indicatif, un seul découpage). 49

B.1 Schéma du dispositif d'enregistrement (vue de dessus, non à l'échelle). 62
B.2 Modèle vierge du formulaire de consentement parental (en arabe). 64
B.3 Autorisation écrite du directeur général de l'établissement (27/05/2025). 66

C.1 Matrices de confusion des quatre expériences sur le jeu de test (35 séquences). . 69
C.2 Courbes de perte et d'accuracy (entraînement et validation) du modèle retenu (Exp1). 72

D.1 Hiérarchie des classes de l'ontologie dans Protégé. 73
D.2 Assertions de propriétés de l'individu Sign_ThankYou dans Protégé. 74

F.1 Attestation de participation à l'École d'été LLMs et langues nationales (Nouadhibou, 23–30 août 2026). 76

Liste des tableaux

1.1 Exigences fonctionnelles du système (EF) 7
1.2 Exigences techniques et contraintes (ET) 7
1.3 Planification du stage (02/05/2026 – 02/09/2026). 13

2.1 Comparaison des principales familles d'approches de reconnaissance des langues des signes 18
2.2 Synthèse comparative des stratégies de fusion multimodale pour la SLR 20
2.3 Une analyse critique de l'approche d'Elsayed & Fathy relève, d'après l'article, cinq limitations que ce mémoire cherche à adresser 23
2.4 Positionnement de la contribution face aux limites des travaux consultés 25

3.1 Caractéristiques du corpus et conditions d'acquisition 28
3.2 Distribution des séquences par classe 28
3.3 Les alternatives disponibles (caractéristiques générales) 29
3.4 Comparatif des architectures de modélisation spatio-temporelle 30
3.5 Comparatif des stratégies d'intégration multimodale 32
3.6 Comparatif des frameworks pour le développement du modèle 32
3.7 Matrice de justification des choix d'architecture 33
3.8 Description phonologique des 7 signes du corpus U-ArSL 37
3.9 Instanciation OWL de l'individu Sign_ThankYou 38

4.1 Répartition stratifiée du jeu de données 40
4.2 Comparaison de la structure de sortie sans et avec enrichissement ontologique . 41

5.1 Métriques globales d'évaluation du modèle retenu (Exp1) 43
5.2 Performances par classe du modèle retenu (Exp1, jeu de test) 44
5.3 Synthèse des études d'ablation (jeu de test, 35 séquences) 44
5.4 Comparaison de la robustesse architecturale (Phase 1 vs Phase 2) 47
5.5 Statut des hypothèses de recherche (H1–H5) dans les conditions de ce corpus . 48
5.6 Positionnement par rapport à quelques travaux de la littérature (résultats rapportés par les auteurs, non directement comparables) 52

Liste des abréviations

Abréviation	Signification
3D-CNN	Three-Dimensional Convolutional Neural Network
AI	Artificial Intelligence (*Intelligence Artificielle*)
ArSL	Arabic Sign Language (*Langue des Signes Arabe*)
ASL	American Sign Language (*Langue des Signes Américaine*)
BiLSTM	Bidirectional Long Short-Term Memory
CNN	Convolutional Neural Network
CPU	Central Processing Unit
DL	Deep Learning (*Apprentissage Profond*)
EF	Exigence Fonctionnelle
ET	Exigence Technique
FPS	Frames Per Second (*Images par seconde*)
GPU	Graphics Processing Unit
HFL	Hierarchical Federated Learning
IA	Intelligence Artificielle
IRI	Internationalized Resource Identifier
KArSL	King Fahd University Arabic Sign Language Dataset
LSTM	Long Short-Term Memory
ML	Machine Learning (*Apprentissage Automatique*)
MLDS	Machine Learning and Data Science
MLOps	Machine Learning Operations
NLP	Natural Language Processing (*Traitement du Langage Naturel*)
OWL	Web Ontology Language
RDF	Resource Description Framework
RGB	Red Green Blue (*Rouge Vert Bleu*)
SLR	Sign Language Recognition (*Reconnaissance de la Langue des Signes*)
SPARQL	SPARQL Protocol and RDF Query Language
U-ArSL	Unified Arabic Sign Language (*Langue des Signes Arabe Unifiée*)
UASL	Unified Arabic Sign Language
W3C	World Wide Web Consortium
YOLO	You Only Look Once

Introduction générale

Contexte. La reconnaissance automatique de la langue des signes est un domaine en pleine expansion, historiquement dominé par les travaux sur la langue des signes américaine (ASL). La Langue des Signes Arabe (ArSL) demeure en revanche sous-représentée dans la recherche en vision par ordinateur, malgré la vaste communauté qu'elle dessert. En Mauritanie, l'enseignement et la communication dans les écoles spécialisées reposent sur la Langue des Signes Arabe Unifiée (U-ArSL) ; ce mémoire s'inscrit dans ce contexte et s'appuie sur un corpus constitué auprès de signeurs mauritaniens.

Problématique. La langue des signes est intrinsèquement multimodale : elle combine la forme et le mouvement des mains avec les expressions faciales et la posture du corps. Or les approches courantes réduisent souvent le signe à une simple étiquette lexicale, sans exploiter les composantes non manuelles ni la structure phonologique du signe. La question centrale de ce travail est la suivante : dans quelle mesure l'intégration conjointe des expressions faciales et de la posture corporelle améliore-t-elle la précision de reconnaissance, par rapport à une approche basée uniquement sur le mouvement des mains ? Quatre questions secondaires portent sur la stratégie de fusion, la typologie des signes, l'explicabilité temporelle de l'attention et la robustesse architecturale.

Objectifs. L'objectif général est de développer une architecture hybride pour la reconnaissance de l'U-ArSL, associant un apprentissage profond multimodal (mains, visage, posture) à une ontologie OWL. Le système reconnaît d'abord un signe, puis lui associe une description sémantique par une requête sur l'ontologie : il ne réalise pas directement une reconnaissance sémantique. Six objectifs spécifiques en découlent : constituer le corpus, numériser le signal multimodal, modéliser la dynamique temporelle, optimiser l'intégration des modalités, évaluer l'apport non manuel et structurer sémantiquement le signe reconnu (section 1).

Contributions. Ce mémoire apporte quatre contributions : un corpus U-ArSL mauritanien de 356 séquences ; une ontologie OWL phonologique couplée au reconnaisseur, interrogée après la classification ; un modèle multimodal compact (quatre branches BiLSTM avec attention et Late Fusion, 149K paramètres) atteignant 97,1 % d'accuracy sur 7 classes en évaluation intra-signeur ; et une étude d'ablation exploratoire dont les résultats sont indicatifs.

Démarche suivie. Les vidéos de signeurs sont converties en séquences de landmarks avec MediaPipe Holistic ; chaque modalité (pose, main gauche, main droite, visage) est traitée par

une branche BiLSTM avec attention, puis les représentations sont fusionnées (Late Fusion) et classifiées. Quatre expériences d'ablation (Exp1 à Exp4) testent les hypothèses H1 à H5, et la prédiction est enrichie a posteriori par l'ontologie OWL.

Organisation du rapport. Le chapitre 1 présente le contexte, l'organisme d'accueil, le cahier des charges et les objectifs. Le chapitre 2 propose l'état de l'art sur la langue des signes arabe, la reconnaissance multimodale et les ontologies. Le chapitre 3 détaille l'analyse, la méthodologie et la conception de la solution. Le chapitre 4 décrit la réalisation et le protocole expérimental. Le chapitre 5 expose les résultats chiffrés et les discute. La conclusion générale synthétise les apports et ouvre des perspectives.

Note sur l'usage d'outils d'IA générative. Un assistant d'IA générative (Claude, Anthropic) a été utilisé pour l'organisation et la mise en forme du rapport selon le modèle LaTeX du département (structure, tableaux, compilation), la traduction du résumé en arabe, et la rédaction de courtes sections de liaison à partir du contenu fourni par l'étudiant. Les résultats expérimentaux, leur interprétation et les conclusions sont ceux de l'auteur, qui assume l'entière responsabilité du contenu.

Chapitre 1

Contexte du projet et organisme d'accueil

1.1 Présentation de l'organisme d'accueil

1.1.1 L'Unité de Recherche Al-Khawarizmi

L'**Unité de Recherche Al-Khawarizmi** (*AI for Optimization and Digital Innovation in Various Fields*) est une équipe mauritanienne de recherche en intelligence artificielle, rattachée à la Faculté des Sciences et Techniques de l'Université de Nouakchott. Ses travaux portent sur l'optimisation et l'innovation numérique dans divers secteurs, afin de répondre à des enjeux nationaux et internationaux tels que la sécurité alimentaire, l'automatisation de l'irrigation et la santé.

Équipe. Elle compte quinze membres :

- **Direction :** Mohamedou El Ghotob Cheikh Tourad, *Assistant Professor* à la Faculté des Sciences et Techniques, spécialisé en intelligence artificielle et science des données ;
- **Coordination :** Cheikh Abdelkader Ahmed Telmoud ;
- **Membres :** neuf doctorants, un assistant de recherche et trois étudiants de master.

Domaines de recherche. Les projets de l'unité couvrent dix domaines : l'apprentissage de similarité, le *Big Data*, l'agriculture, la santé, la vision par ordinateur, la recherche opérationnelle, le traitement automatique du langage naturel, la FinTech, le *Cloud* et l'IoT.

Collaborations. L'unité collabore avec des équipes et laboratoires internationaux, notamment au Maroc, au Canada et en Tunisie : IMT Atlantique, les universités Ibn Zohr, Chouaib Doukkali, Cadi Ayyad, de Carthage et de Yaoundé I, le groupe DLNLP de l'UBC et MBZUAI.

1.1.2 Cadre du stage

Ce mémoire a été réalisé dans le cadre d'un stage de recherche effectué au sein de l'unité du 02/05/2026 au 02/09/2026, sous l'encadrement du Professeur Mohamedade Farouk Nanne. Les activités de l'unité sont présentées sur son site web (`https://al-khawarizmi.vercel.app/`, consulté le 05/10/2026). L'unité a constitué le cadre scientifique dans lequel les travaux

de conception, d'expérimentation et d'évaluation du système présenté dans ce mémoire ont été menés. Ce travail relève du domaine de la vision par ordinateur.

1.1.3 Travail de terrain

Le travail de terrain a été mené au sein d'un établissement spécialisé accueillant des enfants sourds. La constitution du corpus a impliqué dix enfants sourds et a été réalisée avec l'accompagnement d'un enseignant sourd, expert de l'U-ArSL, qui a également contribué à la validation linguistique des signes enregistrés. Cette collaboration avec la communauté sourde a permis d'inscrire le travail dans le contexte réel d'utilisation de l'U-ArSL tel qu'il est enseigné et pratiqué localement.

1.2 Contexte et problématique

La reconnaissance automatique de la langue des signes est un domaine en pleine expansion, historiquement dominé par des travaux axés sur la langue des signes américaine (American Sign Language - ASL). Si l'ASL a bénéficié de nombreux corpus et avancées algorithmiques, la Langue des Signes Arabe (ArSL) demeure encore largement sous-représentée dans la recherche en vision par ordinateur, malgré la vaste communauté qu'elle dessert.

Pour répondre à ce besoin, notre travail s'ancre directement dans le contexte mauritanien. En Mauritanie, l'enseignement et la communication au sein des écoles spécialisées reposent sur la Langue des Signes Arabe Unifiée (U-ArSL). C'est pourquoi le corpus de ce mémoire a été constitué auprès de signeurs mauritaniens pratiquant ce standard académique.

Sur le plan technique, la langue des signes est intrinsèquement multimodale : elle combine la forme et le mouvement des mains avec des expressions faciales et des postures du corps. Traduire cette richesse linguistique nécessite de dépasser les modèles visuels classiques en proposant une approche hybride, capable de capter à la fois le signal temporel et la structure phonologique des signes.

1.2.1 Contexte général

La communication est le pilier de l'intégration sociale, de l'éducation et de l'autonomie individuelle. Pourtant, pour des millions de personnes sourdes et malentendantes à travers le monde, interagir avec une société majoritairement entendante reste un défi quotidien. Dans le monde arabe, la Langue des Signes Arabe (ArSL) constitue le canal naturel d'expression de cette communauté. C'est une langue visuelle et tridimensionnelle d'une grande richesse, où le sens ne repose pas uniquement sur les gestes des mains, mais également sur les expressions du visage, les mouvements du regard et la posture du corps.

Cette marginalisation technologique des langues arabes des signes a toutefois été

partiellement compensée par un effort de standardisation académique : pour pallier la diversité des dialectes régionaux et favoriser l'accès à une éducation inclusive, la Langue des Signes Arabe Unifiée (U-ArSL) a été développée comme un standard académique de référence.

En Mauritanie, cette réalité prend une dimension particulière. Les écoles spécialisées et les centres éducatifs accueillant les élèves sourds à Nouakchott et dans le reste du pays ont adopté l'U-ArSL comme langue d'apprentissage et de structuration linguistique. Malgré cet effort institutionnel, le manque d'outils numériques adaptés crée un fossé persistant entre les élèves sourds et leur environnement. Ce mémoire s'inscrit dans cette dynamique : il vise à tirer parti des avancées récentes du traitement automatique des gestes et du Web sémantique pour concevoir une solution numérique ancrée dans le contexte mauritanien, capable de combler ce fossé et de valoriser l'U-ArSL telle qu'elle est pratiquée localement.

1.2.2 Problématique et motivation

Cette adoption institutionnelle de l'U-ArSL, aussi structurante soit-elle sur le plan pédagogique, ne suffit pas à elle seule à garantir l'inclusion des personnes sourdes dans la société mauritanienne au sens large. Car pour cette communauté, la langue des signes n'est pas un simple outil de communication : elle constitue leur langue première, le support de leur pensée, de leur apprentissage et de leur participation sociale. Or, cette langue demeure largement méconnue en dehors du cercle scolaire et associatif. Il en résulte une fracture linguistique structurelle qui limite l'accès des personnes sourdes aux services publics, aux soins de santé, à la justice et à l'emploi, autant de domaines où la médiation linguistique est rarement disponible, faute d'interprètes en nombre suffisant et d'outils numériques capables de suppléer ce manque.

C'est précisément sur ce second point , l'absence d'outils technologiques adaptés que la recherche en intelligence artificielle devrait apporter une réponse. Or, l'examen de la littérature révèle une limite conceptuelle récurrente dans les systèmes existants : la grande majorité d'entre eux réduisent la tâche de reconnaissance à une simple association entre une séquence vidéo et une étiquette lexicale isolée. Cette formulation méconnaît la nature réelle du signe linguistique. Pour un locuteur sourd, un signe n'est pas une unité atomique équivalente à un mot écrit ; il constitue une unité sémantique composite, où configuration manuelle, expression faciale, posture corporelle et dynamique du mouvement s'articulent simultanément, et non successivement pour produire du sens. En traitant le signe comme une simple étiquette textuelle, les approches actuelles opèrent une simplification qui les empêche de capturer la structure componentielle propre aux langues des signes, et donc de restituer fidèlement l'intention communicative du signeur.

C'est de la conjonction de ces deux constats, l'urgence sociale d'une inclusion linguistique effective des personnes sourdes en Mauritanie, et l'insuffisance des modèles computationnels existants face à la complexité structurelle de la langue des signes, que naît la motivation

de ce mémoire. Nous proposons une approche neuro-symbolique qui dépasse le cadre de la classification lexicale : plutôt que de se limiter à la prédiction d'un mot, elle vise à enrichir le signe reconnu d'une description phonologique et sémantique, en articulant perception visuelle multimodale (classification) et modélisation explicite des connaissances linguistiques (ontologie interrogée après la classification).

Cette motivation est également personnelle : pratiquant l'U-ArSL depuis 2025, nous avons pu constater directement, au contact des signeurs mauritaniens, l'écart entre la richesse expressive de cette langue et la simplicité des outils technologiques existants, une observation qui a nourri le choix d'une approche neuro-symbolique fidèle à cette complexité.

1.2.3 Note sur la terminologie

Ce mémoire étant rédigé en français, un choix terminologique est explicité ici une fois pour toutes : les termes techniques issus de l'apprentissage automatique et de l'ingénierie ontologique (Late Fusion, Early Fusion, Handshape, Location, Movement, Dropout, Softmax, etc.) sont volontairement conservés en anglais tout au long du document, plutôt que traduits. Ce choix garantit la correspondance directe entre le texte du mémoire, le code source (05_Code_Source) et les classes/propriétés de l'ontologie OWL (sign_language_ontology.owl), et suit l'usage standard de la littérature scientifique internationale en apprentissage automatique. Dans ce mémoire, le terme « hybride » désigne l'association d'une reconnaissance neuronale et d'un enrichissement sémantique post-hoc : l'ontologie est interrogée après la prédiction et n'intervient ni dans l'apprentissage ni dans la décision. Il ne s'agit donc pas d'un raisonnement neuro-symbolique au sens strict, qui constitue une perspective de ce travail.

1.3 Cahier des charges

L'idée de ce projet n'est pas née dans un laboratoire abstrait, mais d'un constat quotidien : l'isolement des personnes sourdes et malentendantes dans nos sociétés face à des services essentiels (santé, administration, éducation). Réduire ce fossé nécessitait de concevoir une technologie capable de comprendre la langue des signes non pas comme de simples gestes mécaniques, mais comme un langage riche, expressif et contextuel.

Ce travail s'est déroulé en deux phases distinctes :

Phase 1 — Collecte et exploration (2025) : constitution du corpus vidéo et premières expérimentations. Une approche par apprentissage d'embeddings (*transfer learning* et *triplet loss* [1, 2]) a d'abord été envisagée, puis abandonnée. Le modèle effectivement évalué en Phase 1 est un **BiLSTM à flux unique** (934 215 paramètres, Dropout de 0,2), entraîné sur **9 classes** (accuracy de 91,3 %, avec un surapprentissage marqué) ; il sert de modèle de référence pour la comparaison avec la Phase 2 (Tableau 5.4). Le passage de 9 à 7 classes en Phase 2 s'explique par un volume de données jugé insuffisant pour certains signes : seuls les signes correctement

exécutés et validés ont été conservés. Cette phase exploratoire a produit le jeu de données brut qui sert de base au projet actuel.

Phase 2 — Approche actuelle : cette phase constitue la contribution scientifique et technique majeure de ce mémoire. Elle repose sur la collecte et la structuration d'un jeu de données expérimental propre, couplée à une refonte complète de la méthodologie de classification autour d'une architecture multi-branches BiLSTM + Attention avec Late Fusion multimodale, elle-même couplée à une ontologie formelle OWL pour dépasser la simple étiquette-mot.

1.3.1 Spécifications fonctionnelles

Pour répondre à cette problématique et guider le développement de la solution, les exigences fonctionnelles fondamentales du système ont été formalisées dans le Tableau 1.1.

Tab. 1.1 : Exigences fonctionnelles du système (EF)

ID	Exigence	Priorité	Statut
EF-01	Extraire les landmarks (mains, visage, corps) à partir d'une séquence vidéo	Essentielle	Réalisée
EF-02	Classifier une séquence de landmarks en un signe reconnu	Essentielle	Réalisée
EF-03	Produire une sortie liée à l'ontologie (pas seulement une étiquette texte)	Essentielle	Réalisée
EF-04	Permettre l'ajout de nouveaux signes sans réentraînement complet	Souhaitable	Non réalisée (perspective)
EF-05	Démonstration (script) testant une séquence et affichant la prédiction	Essentielle	Réalisée

1.3.2 Exigences techniques et contraintes

Afin de garantir la faisabilité technique, la précision temporelle et l'interopérabilité sémantique, des contraintes d'implémentation strictes ont été définies (Tableau 1.2).

Tab. 1.2 : Exigences techniques et contraintes (ET)

ID	Contrainte	Valeur cible
ET-01	Framework d'extraction de features	MediaPipe Holistic
ET-02	Modèle de classification temporelle	BiLSTM + mécanisme d'attention
ET-03	Stratégie de fusion multimodale	Late Fusion (comparée à Early Fusion)
ET-04	Vitesse d'extraction des features	Objectif : extraction compatible avec un usage en temps réel sur CPU (non mesurée précisément dans ce travail)
ET-05	Framework d'implémentation	TensorFlow / Python

1.3.3 Cadre expérimental et contraintes de l'étude

Délimitation de l'espace de recherche : fixation des contraintes techniques pour la reconnaissance isolée de l'ArSL dans des conditions réelles (éclairage ambiant, occultations partielles, variabilité de vitesse d'exécution).

Exigences d'acquisition : définition des paramètres spatio-temporels (29,97 fps, résolution standard) et ciblage d'un modèle léger capable de tourner en temps réel sans infrastructure lourde.

1.3.4 Considérations éthiques et périmètre du projet

Les participants à la collecte sont des enfants sourds, scolarisés dans un établissement spécialisé où l'U-ArSL est la langue d'enseignement. Travailler avec des mineurs et enregistrer leur image exigeait une responsabilité morale et juridique particulière. Avant tout enregistrement, un protocole d'information et de consentement éclairé a été mis en place auprès des familles. Obtenir l'accord signé des parents n'était pas une simple formalité administrative, mais le socle de confiance indispensable pour mener cette collecte dans le respect des droits des mineurs.

- **Consentement éclairé et cadre légal :** signature d'un document d'autorisation par les tuteurs légaux des enfants, autorisant la captation vidéo et l'utilisation des données pour la recherche et le développement de logiciels (modèle en Annexe B). Le formulaire prévoit que ces données puissent servir à un projet susceptible d'évoluer ultérieurement en application, entreprise émergente ou service numérique. Dans le cadre de ce mémoire, elles sont utilisées **exclusivement à des fins de recherche scientifique**.
- **Autorisation de l'établissement et accord des enfants :** l'établissement spécialisé a donné son autorisation écrite, par une lettre signée de son directeur général et datée du 27/05/2025 (Annexe B). Cette lettre autorise la collecte de données vidéo en langue des signes pour le développement d'une application, à condition de respecter l'éthique professionnelle et la vie privée des participants, et exclut tout usage commercial ou personnel sans autorisation écrite préalable de l'établissement. L'accord des enfants a également été recueilli, en plus du consentement écrit de leurs tuteurs légaux (formulaire parental en Annexe B).
- **Protection des données personnelles :** le traitement des données s'inscrit dans le cadre de la loi mauritanienne n° 2017-020 du 22 juillet 2017 relative à la protection des données à caractère personnel. Les dispositions prises sont : le consentement écrit des tuteurs légaux, la conservation privée des vidéos brutes sans diffusion, l'utilisation des seuls landmarks pour l'entraînement des modèles et l'engagement de ne pas partager les données avec des tiers étrangers au projet. Aucune déclaration auprès de l'autorité de protection des données (APD) n'a encore été effectuée.
- **Retrait du consentement :** le formulaire (Annexe B) indique que le parent ne peut plus retirer son consentement une fois les données de l'enfant intégrées à la base. Cette clause

est trop restrictive au regard des principes éthiques usuels : il est proposé de réviser le formulaire afin de permettre le retrait du consentement et de supprimer, sur demande, les données de l'enfant concerné de toute utilisation future.

- **Rôle du second étudiant cité dans le formulaire :** le formulaire présente deux étudiants du Master MLDS. Le second, Oussama Mohamed Aly Deddah (co-auteur de l'article), a participé à la collecte des données et à la Phase 1 du modèle.
- **Participation de la communauté sourde et validation linguistique :** la sélection des expressions, l'encadrement des enregistrements et la vérification de chaque séquence ont été assurés par un enseignant sourd, expert de l'U-ArSL. Sa participation garantit que les signes du corpus correspondent à l'usage réel de la langue enseignée, et que les séquences retenues sont correctement exécutées.
- **Protection des participants :** chaque session d'enregistrement s'est déroulée sous la supervision de cet enseignant, afin d'assurer la qualité des enregistrements et le bien-être des enfants.
- **Conservation et utilisation des vidéos :** les vidéos brutes sont conservées de manière privée par l'auteur et ne font l'objet d'aucune diffusion publique. Leur seule utilisation en dehors de l'entraînement du modèle est la démonstration du système présentée lors de la soutenance, dans le cadre académique de cette recherche.
- **Caractère identifiant des landmarks :** le modèle travaille sur des coordonnées squelettiques extraites par MediaPipe (543 landmarks 3D), et non sur les images. Ces coordonnées ne peuvent toutefois pas être considérées comme totalement anonymes : la géométrie du visage (468 points) peut contenir des informations biométriques potentiellement identifiantes. Toute diffusion future du corpus, même sous forme de landmarks, serait donc soumise à l'accord des tuteurs légaux.

Hors périmètre de ce travail :

- la reconnaissance en temps réel sur flux vidéo continu (seules des séquences segmentées sont traitées) ;
- les langues des signes nationales arabes non unifiées (le corpus utilise exclusivement le standard U-ArSL) ;
- le déploiement en production ou en application mobile ;
- les énoncés en contexte de phrase continue (seules des expressions segmentées individuellement sont traitées).

1.3.5 Délimitation du champ d'étude et hiérarchisation des travaux

Afin de garantir la rigueur expérimentale et la faisabilité technique de cette étude dans le cadre imparti, les axes de recherche ont été hiérarchisés en distinguant le socle fondamental développé dans ce mémoire des évolutions méthodologiques ultérieures.

Reconnaissance sur séquences segmentées vs Flux vidéo continu : Socle actuel :

Traitement et évaluation sur des séquences gestuelles segmentées (signes isolés) pour établir la preuve de concept du modèle neuro-symbolique et valider l'architecture d'attention multi-branches.

Extension future : Adaptation du pipeline à un flux vidéo continu temps réel avec segmentation temporelle automatique (continuous sign language recognition).

Standardisation U-ArSL vs Variantes dialectales régionales : Socle actuel : Focalisation sur la Langue des Signes Arabe Unifiée (U-ArSL) afin de construire une base ontologique et squelettique stable et normalisée.

Extension future : Extension du modèle ontologique OWL pour couvrir les variations dialectales et régionales (ex : dialecte mauritanien local).

Génération sémantique du signe isolé vs Syntaxe de la phrase continue : Socle actuel : Modélisation phonologique et reconnaissance au niveau du signe isolé pour valider l'alignement entre l'apprentissage profond (Keras) et le raisonnement sémantique (OWL).

Extension future : Prise en charge des structures syntaxiques complexes et de la grammaire de phrases continues (Sign Language Translation).

Validation expérimentale en laboratoire vs Déploiement applicatif : Socle actuel : Validation expérimentale des performances du modèle, de la matrice de confusion et de la précision d'inférence neuro-symbolique.

Extension future : MLOps, conteneurisation embarquée et déploiement sous forme d'application mobile ou web temps réel.

1.4 Objectifs et périmètre

1.4.1 Objectif général

Ce travail vise à développer une architecture hybride, associant un réseau neuronal multimodal et une ontologie OWL, pour la reconnaissance de la Langue des Signes Arabe Unifiée (U-ArSL), telle qu'enseignée et pratiquée au sein des institutions spécialisées en Mauritanie. Il s'agit d'associer un apprentissage profond multimodal, fusionnant les mouvements des mains, les expressions faciales et la posture corporelle collectés auprès de signeurs mauritaniens, à une ontologie OWL. Cette couche sémantique permet au système de dépasser la simple prédiction d'une étiquette-mot pour accéder à une compréhension phonologique et linguistique profonde du signe reconnu.

1.4.2 Objectifs spécifiques

Pour concrétiser cet objectif général et répondre aux défis méthodologiques de la reconnaissance de l'U-ArSL en Mauritanie, ce travail se décline en six objectifs spécifiques interdépendants :

Ancrage empirique et constitution du corpus : constituer et consolider un jeu de données vidéo d'U-ArSL auprès de signeurs mauritaniens, afin de disposer d'une base empirique représentative de la réalité pédagogique locale.

Numérisation du signal multimodal : extraire les caractéristiques spatiotemporelles des mains, du visage et de la posture via MediaPipe Holistic, transformant le mouvement humain brut en une représentation numérique exploitable.

Modélisation de la dynamique temporelle : concevoir une architecture neuronale multi-branches intégrant des couches BiLSTM et un mécanisme d'attention, capable de capturer la chronologie et la subtilité des gestes.

Optimisation de l'intégration des modalités : comparer expérimentalement les stratégies de fusion précoce (Early Fusion) et tardive (Late Fusion) afin de déterminer la meilleure manière d'associer les flux d'informations.

Évaluation de l'apport non-manuel : quantifier par une étude d'ablation la contribution exacte des expressions faciales et de la posture par rapport aux seuls mouvements des mains.

Structuration sémantique et explicabilité : concevoir une ontologie OWL phonologique reliant chaque signe reconnu à ses propriétés linguistiques, afin de transformer une prédiction numérique brute en une connaissance interprétable et exploitable par un tiers.

1.4.3 Questions de recherche et hypothèses

La conception d'un système neuro-symbolique pour la reconnaissance de l'U-ArSL en Mauritanie soulève des interrogations fondamentales sur la manière dont les différentes modalités gestuelles interagissent et doivent être modélisées. Pour guider cette démarche expérimentale, notre recherche s'articule autour d'une question centrale et de quatre questions secondaires, chacune assortie d'une hypothèse de travail :

Question centrale (QR1) — L'apport du multimodal *Dans quelle mesure l'intégration conjointe des expressions faciales et de la posture corporelle améliore-t-elle la précision de reconnaissance, par rapport à une approche basée uniquement sur le mouvement des mains ?*

H1 : l'ajout des expressions faciales et de la posture corporelle améliore significativement la précision de reconnaissance par rapport à un modèle n'exploitant que les mouvements des mains.

Question secondaire (QR2) — La stratégie d'intégration *La fusion tardive (Late Fusion) des différentes branches d'information est-elle plus efficace que la fusion précoce (Early Fusion) pour capturer la complémentarité des modalités ?*

H2 : la fusion tardive permet une meilleure exploitation de la complémentarité entre modalités que la fusion précoce, en préservant plus longtemps la spécificité de chaque flux d'information.

Question secondaire (QR3) — La typologie des signes *Quels types de signes (dominés par les mains, dépendants du visage ou dépendants du corps) bénéficient le plus de l'apport des*

composantes non-manuelles ?

H3 : les signes dont la distinction lexicale repose sur une composante non-manuelle (expression faciale ou posture) bénéficient davantage de l'apport multimodal que les signes dont le sens est porté principalement par la configuration manuelle.

Question secondaire (QR4) — L'explicabilité temporelle *Le mécanisme d'attention couplé au BiLSTM permet-il d'identifier précisément les images (frames) les plus discriminantes d'un signe au cours de son exécution ?*

H4 : le mécanisme d'attention attribue des poids significativement plus élevés aux frames correspondant aux phases articulatoires clés du signe (transitions et tenues), ce qui rend le processus de décision du modèle interprétable.

Question secondaire (QR5) — La robustesse architecturale Une architecture à paramétrage réduit et à régularisation renforcée permet-elle de mieux généraliser qu'une architecture de référence à forte capacité ? **H5** : une architecture multi-branches à paramétrage réduit et à régularisation renforcée (Dropout élevé, L2, EarlyStopping) présente moins de surapprentissage qu'une architecture single-stream à forte capacité, même sur un corpus de taille limitée.

1.4.4 Contributions du travail

À l'intersection de la vision par ordinateur, du Web sémantique et du contexte éducatif mauritanien, ce mémoire apporte quatre contributions :

1. **Un corpus U-ArSL mauritanien.** À notre connaissance, un jeu de données original de 356 séquences vidéo, converties en landmarks MediaPipe Holistic, enregistrées auprès de dix enfants sourds mauritaniens et validées par un enseignant sourd, expert de l'U-ArSL.
2. **Une ontologie OWL phonologique couplée au reconnaisseur.** Une formalisation des composantes manuelles (forme, orientation, mouvement, emplacement) et non manuelles (expression faciale, posture) de chaque signe du corpus. Elle est interrogée après la classification pour associer à chaque signe prédit une description phonologique et sémantique, et pour appuyer l'analyse des erreurs.
3. **Un modèle multimodal compact.** Une architecture à quatre branches (pose, main gauche, main droite, visage) avec BiLSTM, attention additive et Late Fusion (148 907 paramètres), qui atteint 97,1 % d'accuracy sur 7 classes dans une évaluation intra-signeur.
4. **Une étude d'ablation exploratoire.** Une comparaison des modalités d'entrée, de la stratégie de fusion et de l'attention, dont les résultats sont indicatifs (35 séquences de test, une seule initialisation aléatoire par configuration).

Précision importante : le système ne réalise pas directement une reconnaissance sémantique. Il reconnaît d'abord un signe (classification), puis lui associe, a posteriori, une description

sémantique par une requête sur l'ontologie.

Enfin, une partie des résultats issus de ce travail a fait l'objet d'un article scientifique accepté à la conférence internationale I2COMSAPP'26, constituant ainsi une première valorisation scientifique des travaux réalisés.

1.5 Planification

Le projet s'est déroulé en deux temps. La collecte du corpus auprès des enfants sourds a été réalisée en 2025, avant le stage. Le stage de recherche proprement dit, du 02/05/2026 au 02/09/2026 (quatre mois), a porté sur l'extraction des landmarks, la conception et l'entraînement des modèles, les expériences d'ablation, la construction de l'ontologie OWL, l'évaluation des résultats et la rédaction du mémoire. Le Tableau 1.3 présente le déroulement de ces phases.

Tab. 1.3 : Planification du stage (02/05/2026 – 02/09/2026).

Phase	Période	P1	P2	P3	P4	P5	P6	P7	P8	P9
Extraction des landmarks (MediaPipe) et prétraitement	02/05 – 29/05	■	■							
Conception et entraînement du modèle BiLSTM + attention (Phases 1 et 2)	16/05 – 10/07		■	■	■	■	■			
Expériences d'ablation (Exp1 à Exp4)	27/06 – 07/08					■	■	■		
Ontologie OWL (Protégé) et liaison aux prédictions	11/07 – 21/08						■	■	■	
Évaluation et analyse des résultats	25/07 – 21/08							■	■	
Rédaction du mémoire	08/08 – 02/09								■	■

P1 = 02/05 – 15/05 ; P2 = 16/05 – 29/05 ; P3 = 30/05 – 12/06 ; P4 = 13/06 – 26/06 ; P5 = 27/06 – 10/07 ; P6 = 11/07 – 24/07 ; P7 = 25/07 – 07/08 ; P8 = 08/08 – 21/08 ; P9 = 22/08 – 02/09.

1.6 Conclusion du chapitre

Le cadre du travail, la problématique, les exigences et les objectifs étant posés, le chapitre suivant situe ce travail dans la littérature scientifique.

Chapitre 2

État de l'art

Ce chapitre dresse un panorama critique de la littérature scientifique à l'intersection de la vision par ordinateur, de la reconnaissance automatique de la langue des signes et des technologies du Web sémantique. L'objectif est de situer notre travail au sein des avancées algorithmiques récentes, tout en identifiant précisément les verrous méthodologiques que **ce mémoire** cherche à lever.

Dans un premier temps, nous analyserons les spécificités de la Langue des Signes Arabe (ArSL) et les difficultés inhérentes à sa modélisation computationnelle. Nous examinerons ensuite les architectures basées sur l'apprentissage profond multimodal et les modèles temporels. Enfin, nous aborderons l'apport des ontologies OWL et des systèmes neuro-symboliques pour la représentation explicable des connaissances gestuelles.

2.1 Problématique de la Langue des Signes Arabe

La reconnaissance automatique de la langue des signes (SLR — *Sign Language Recognition*) constitue un champ de recherche complexe à la croisée du traitement d'images, de la modélisation temporelle et de la linguistique computationnelle. Alors que la littérature internationale s'est abondamment développée autour de la langue des signes américaine (ASL) ou de la langue des signes allemande (DGS), les travaux consacrés à la Langue des Signes Arabe (ArSL) restent confrontés à des défis théoriques et pratiques majeurs.

2.1.1 La nature visuo-gestuelle et tridimensionnelle du signe

Sur le plan linguistique, l'ArSL est une langue visuo-gestuelle tridimensionnelle qui repose sur l'articulation simultanée de deux canaux d'information :

Les composantes manuelles : la configuration des doigts et de la paume (*handshape*), l'orientation de la main (*orientation*), le lieu d'exécution sur le corps ou dans l'espace neutre (*location*), ainsi que la trajectoire spatiotemporelle (*movement*).

Les composantes non-manuelles : les expressions faciales, les mouvements oculaires et buccaux (*mouthings/mouthes*), ainsi que les inclinaisons de la tête et de la posture corporelle.

En ArSL, les composantes non-manuelles ne jouent pas un rôle purement expressif : elles portent des fonctions lexicales et grammaticales indispensables. Une variation de l'expression faciale ou une inclinaison du buste peut transformer une affirmation en interrogation, ou

modifier la polarité sémantique d'un geste manuel identique. La capture synchrone de ces deux canaux constitue le premier défi modélisateur, au cœur des travaux interdisciplinaires sur la reconnaissance, la génération et la traduction des langues des signes [3].

2.1.2 La réduction du signe à une étiquette lexicale brute

Le premier constat critique issu de la littérature concerne la formulation même du problème de reconnaissance. La grande majorité des systèmes actuels produisent une correspondance directe du type **Vidéo/Image** $\rightarrow$ **Mot/Texte**. C'est précisément ce que montrent les travaux récents de la littérature :

Obi et al. [4] reconnaissent les lettres de l'ASL pour les convertir directement en texte.

Alsharif et al. [5] combinent YOLOv11 et MediaPipe pour détecter des gestes et les mapper à des étiquettes brutes.

Algethami et al. [6] construisent un pipeline vidéo $\rightarrow$ MediaPipe $\rightarrow$ TCN/BiLSTM $\rightarrow$ étiquette de phrase.

Dans l'ensemble de ces travaux, le résultat produit est, à notre connaissance, un mot ou un label textuel plutôt qu'une représentation sémantique structurée du signe lui-même. Cette approche par « boîte noire » paraît limitée sur le plan scientifique : elle ne permet guère de gérer la polysémie (un même signe ayant des sens variés selon le contexte) et crée une dépendance stricte à la langue cible, empêchant toute interopérabilité entre variantes de l'ArSL.

2.1.3 L'absence d'annotations phonologiques dans les jeux de données

Ibrahim et al. [7] soulignent explicitement que la langue des signes arabe égyptienne (EASL) demeure sous-étudiée et que les ressources existantes souffrent de limitations critiques. Le dataset ArSL2018, bien qu'abondamment utilisé (54 049 images), se limite à des signes isolés et statiques.

Surtout, à notre connaissance, aucun des jeux de données d'ArSL consultés n'intègre d'annotations phonologiques formelles : les séquences sont annotées par le mot global correspondant, sans description fine des paramètres manuels (*handshape*, *location*, *movement*, *orientation*) ni non-manuels. Même dans les initiatives récentes comme celle d'Algethami et al. [6] qui proposent un dataset de 3 046 vidéos et extraient 258 points clés par frame via MediaPipe , les données extraites restent des coordonnées numériques brutes. Dans les travaux consultés, elles ne sont pas articulées autour d'une taxonomie phonologique ou conceptuelle structurée.

2.1.4 Le morcellement dialectal et l'absence de standardisation

L'ArSL n'existe pas sous une forme unique et universelle. Comme le confirment Ibrahim et al. [7], l'EASL « combine des éléments de l'arabe standard moderne, des dialectes égyptiens et des influences régionales », ce qui rend un modèle entraîné sur une région difficilement transposable à une autre. Elsayed & Fathy [8] observent également que l'ArSL présente de multiples variantes et dialectes selon les pays, voire au sein d'un même territoire national ; Abdel-Fattah [9] décrit lui aussi cette diversité des langues des signes arabes. Cette forte variabilité intra-classe dégrade considérablement la capacité de généralisation des réseaux de neurones profonds lorsqu'ils sont confrontés à des variantes régionales non vues, comme l'U-ArSL en Mauritanie.

2.1.5 L'arrêt à la reconnaissance statistique sans compréhension sémantique

Au-delà du problème de formulation identifié en 2.1.2, un second défi, cette fois lié à la performance même des modèles plutôt qu'à leur conception, mérite d'être souligné. Malgré l'obtention de performances métriques remarquables dans la littérature récente Algethami et al. [6] atteignant 99,5 % de précision avec une architecture TCN, et Alsharif et al. [5] obtenant 98,2 % de mAP , ces architectures souffrent d'un déficit d'explicabilité. Autrement dit, un score élevé ne garantit pas une compréhension du signe : ces systèmes détectent la présence d'un signe à partir de motifs statistiques, mais ne possèdent pas, a priori, de niveau de « compréhension » du sens représenté. Il existe un saut qualitatif, que ces travaux ne semblent pas franchir, entre la classification de signaux visuels et l'interprétation sémantique raisonnée du concept exprimé.

Transition Ces cinq constats, nature composite du signe, réduction lexicale, absence d'annotation phonologique, morcellement dialectal, et opacité sémantique des modèles performants dessinent les limites structurelles de l'état actuel de la reconnaissance de l'ArSL. La section suivante examine plus en détail les architectures d'apprentissage profond mobilisées dans ces travaux, avant d'évaluer, en 2.3 et 2.4, dans quelle mesure les approches multimodales et les ontologies existantes permettent ou non de dépasser ces limites.

2.2 Approches existantes pour la reconnaissance des langues des signes

La reconnaissance automatique de la langue des signes a connu une évolution méthodologique majeure au cours de la dernière décennie. Historiquement dépendante de capteurs physiques (*data gloves*) ou de descripteurs visuels faits à la main (*hand-crafted features*), la discipline s'appuie désormais sur l'apprentissage profond et les représentations

squelettiques (*pose estimation*). Cette section passe en revue les grandes familles d'approches de la littérature, en analysant leurs apports et leurs limites pour la modélisation de l'U-ArSL.

2.2.1 Approches basées sur la vision directe vs. capteurs physiques

Dans les premiers travaux de SLR, les chercheurs ont abondamment recouru à des dispositifs matériels dédiés :

Capteurs physiques et gants intelligents : Ces systèmes mesurent directement la flexion des doigts et la cinématique du poignet via des accéléromètres ou des capteurs de flexion. Bien qu'ils offrent une grande précision spatiale, ils restent intrusifs, coûteux et peu adaptés à un usage naturel ou éducatif au quotidien.

Vision par ordinateur directe (basée sur l'image brute) : Les approches fondées sur l'analyse directe de la vidéo (RGB/RGB-D) appliquent des réseaux de neurones convolutifs (CNN 2D ou 3D) directement sur les pixels. Bien qu'efficaces pour capturer la texture et l'apparence, ces modèles sont extrêmement sensibles aux variations de fond, d'éclairage, d'habillement et à la couleur de peau des signeurs, ce qui limite sévèrement leur généralisation.

2.2.2 Modélisation temporelle et architectures profondes multimodales

Pour capturer la dynamique temporelle du signe, la littérature récente a délaissé les modèles de Markov cachés (HMM, étendus à de grands vocabulaires [10]) au profit d'architectures récurrentes et attentionnelles :

Réseaux récurrents (LSTM et BiLSTM) : Les réseaux *Bidirectional Long Short-Term Memory* (BiLSTM [11, 12]) se sont imposés pour traiter la nature séquentielle du geste. En analysant la séquence à la fois dans le sens chronologique et rétrograde, le BiLSTM capture les dépendances contextuelles longues entre le début, le paroxysme (*stroke*) et la résolution du signe. Cette approche est notamment mobilisée par Algethami et al. [6] dans leur pipeline de reconnaissance continuous de l'ArSL, combinant extraction MediaPipe et modélisation temporelle par TCN/BiLSTM. D'autres travaux associent des poses de la main à un apprentissage profond optimisé par des algorithmes métaheuristiques [13], et des applications éducatives existent, par exemple l'apprentissage de l'ASL en réalité virtuelle [14].

Mécanismes d'attention et Transformers : L'intégration de mécanismes d'attention (comme l'attention additive [15]) permet au réseau de pondérer dynamiquement les *frames* les plus informatives d'une séquence vidéo, réduisant l'impact des phases de transition neutres entre deux gestes, un principe qu'exploitent Alsharif et al. [5] dans leur système de suivi de points clés en temps réel combinant YOLOv11 et MediaPipe.

Fusion multimodale (Early vs. Late Fusion) : Les architectures les plus performantes adoptent des stratégies de fusion pour combiner les différentes modalités (mains, visage,

posture). Alors que l'*Early Fusion* concatène les données dès l'entrée, au risque de diluer l'information spécifique à chaque modalité, la *Late Fusion* entraîne des branches spécialisées pour chaque sous-ensemble de points clés avant de fusionner leurs représentations latentes, une distinction conceptuelle formalisée par Baltrušaitis, Ahuja & Morency [16] dans leur taxonomie de référence de l'apprentissage automatique multimodal.

2.2.3 Extraction de repères squelettiques (*Keypoints/Landmarks*)

L'émergence d'outils d'estimation de pose en temps réel tels que MediaPipe [17] ou OpenPose a marqué un tournant méthodologique décisif. En convertissant un flux vidéo haute résolution en une série temporelle compacte de coordonnées spatiales (x,y,z), ces pipelines apportent deux avantages majeurs :

Invariance visuelle et vie privée : Le modèle ne traite que la géométrie du squelette, devenant largement insensible au décor, à la luminosité ou à l'apparence physique du signeur.

Réduction significative de la complexité computationnelle : Passer de matrices de pixels volumineuses à des vecteurs de repères normalisés réduit très fortement le coût de calcul, rendant possible le déploiement sur des dispositifs légers (*edge computing*).

Cependant, comme identifié dans la section précédente, la simple extraction de coordonnées (x,y,z) brutes ne constitue pas une modélisation phonologique en soi : ces nombres flottants doivent impérativement être structurés et interprétés pour accéder à une réelle compréhension sémantique.

Tab. 2.1 : Comparaison des principales familles d'approches de reconnaissance des langues des signes

Approche / Famille	Principaux avantages	Limites majeures
Capteurs physiques (gants)	Grande précision des degrés de liberté	Intrusif, coûteux, manque de naturalité
CNN 2D/3D (RGB brute)	Capture fine des textures et formes	Sensible au fond, à la lumière et à l'apparence
Squelettes + BiLSTM / Attention	Invariant au décor, léger, saisit le contexte temporel	Reste une boîte noire statistique sans raisonnement symbolique

2.3 Approches multimodales et fusion d'informations

La reconnaissance efficace des langues des signes repose sur l'intégration cohérente de multiples canaux d'information, reflétant la nature fondamentalement multimodale de la communication gestuelle. En langue des signes, le sens ne réside pas uniquement dans la configuration des mains, mais émerge de la combinaison simultanée des composants manuels (*handshapes*, orientations, mouvements, emplacements) et non-manuels (expressions faciales, mouvements des sourcils, de la bouche et postures du corps).

2.3.1 Modalités manuelles vs. non-manuelles

La modélisation informatique distingue deux catégories de flux d'entrée :

Modalités manuelles (Mains gauche et droite) : Elles véhiculent la composante lexicale majeure du signe. L'analyse séparée ou conjointe des articulations des doigts (21 repères 3D par main via MediaPipe) permet de capturer la cinématique fine, le changement de forme (*handshape*) et la trajectoire spatio-temporelle.

Modalités non-manuelles (Visage et Posture) : Souvent négligées dans les travaux initiaux, les composantes non-manuelles portent une charge linguistique essentielle [18]. La branche faciale englobe les expressions, le regard, la dynamique de la bouche (*mouthings* / *mouthing words*) et la position des sourcils (qui distinguent notamment les questions ouvertes des questions fermées). La posture globale (torse, épaules) marque quant à elle les changements de rôles énonciatifs et les structures syntaxiques.

2.3.2 Taxonomie des stratégies de fusion (*Early, Late, Hybrid*)

L'intégration de ces différents flux vectoriels nécessite des stratégies d'architecture d'apprentissage dédiées. Selon la taxonomie établie par Baltrušaitis, Ahuja & Morency [16], trois paradigmes de fusion prévalent :

Early Fusion (Fusion précoce / au niveau des caractéristiques) : Les vecteurs de caractéristiques extraits de chaque modalité (p. ex. concaténation directe des coordonnées x,y,z de la posture, des mains et du visage) sont regroupés en une matrice unique avant d'être transmis au réseau temporel.

Avantage : Modélise les corrélations inter-modalités dès les premières couches.

Limite : Risque de dominance des modalités à haute dimensionnalité (ex. le visage et ses 468 repères) au détriment des caractéristiques plus compactes mais hautement discriminantes (ex. les 21 repères des mains).

Late Fusion (Fusion tardive / au niveau des décisions) : Des branches de réseaux spécialisées (ex. BiLSTM dédiés) sont entraînées de manière autonome sur chaque sous-ensemble de points clés. Les représentations latentes ou les distributions de probabilités de sortie sont ensuite combinées à la fin du réseau (par concaténation, moyenne pondérée ou couche fully-connected finale).

Avantage : Préserve l'intégrité et la dynamique propre à chaque modalité sans dilution.

Limite : Néglige les interactions synchrones à bas niveau entre les mouvements des mains et les expressions faciales.

Hybrid Fusion (Fusion hybride) : Combine la flexibilité des branches autonomes avec des mécanismes d'inter-attention (*cross-attention*), permettant aux caractéristiques des mains de guider l'attention faciale et inversement au fil du traitement séquentiel.

Tab. 2.2 : Synthèse comparative des stratégies de fusion multimodale pour la SLR

Stratégie de Fusion	Niveau d'intégration	Modélisation des interactions	Complexité & Risques
Early Fusion	Caractéristiques brutes / Entrée	Précoce, globale	Risque de saturation / déséquilibre de dimensionnalité
Late Fusion	Représentations latentes / Décision	Tardive, au niveau décisionnel	Légère, indépendance des branches, spécialisation forte
Hybrid Fusion	Multi-niveaux (Cross-Attention)	Dynamique, continue	Plus complexe à entraîner, coût computationnel accru

2.4 De la représentation sémantique à l'ingénierie des connaissances : Fondements et limites des modèles symboliques

Avant d'aborder le rôle spécifique de l'ontologie dans la modélisation phonologique de la langue des signes, il convient de situer cette approche dans l'évolution globale des structures de représentation des connaissances en IA. La modélisation de la sémantique a en effet connu une trajectoire progressive, caractérisée par une formalisation croissante de la logique et du sens.

2.4.1 Panorama exhaustif des formalismes de représentation du sens

Historiquement, la structuration du savoir en informatique s'est appuyée sur plusieurs paradigmes symboliques, chacun apportant un niveau d'abstraction distinct :

Les réseaux sémantiques (*Semantic Networks*) : Premières tentatives d'organisation sous forme de graphes (*nœuds* pour les concepts, *arcs* pour les relations), ils offrent une intuitivité visuelle mais manquent d'une sémantique formelle rigoureuse, générant des ambiguïtés d'interprétation à mesure que le réseau gagne en complexité.

Les modèles basés sur les cadres (*Frame-based Models*) : Introduits pour structurer l'information en entités plus riches (objets/cadres munis de *slots* ou d'attributs), ils facilitent la modélisation hiérarchique mais restent limités pour exprimer des contraintes logiques globales et du raisonnement inter-objets.

Les graphes conceptuels (*Conceptual Graphs*) : Ancrés dans la logique des prédicats du premier ordre, ils formalisent la relation entre concepts et relations via un graphe bipartite, apportant une meilleure rigueur mathématique mais au prix d'une lourdeur d'implémentation pour le traitement automatique à grande échelle.

Les graphes de connaissances (*Knowledge Graphs*) : Largement adoptés pour la gestion de données massives interconnectées, ils permettent d'associer des triplets (sujet, prédicat, objet) sur de vastes bases de données. Toutefois, ils demeurent essentiellement orientés sur les données

(*data-driven*) et dépourvus de contraintes d'inférence stricte.

2.4.2 Limites des représentations classiques

Bien que ces formalismes classiques aient posé les bases de l'IA symbolique, ils se révèlent insuffisants pour capturer la complexité d'un système linguistique tridimensionnel comme la langue des signes :

Incapacité à gérer des contraintes phonologiques strictes : Un simple graphe de connaissances s'en tient à l'association passive de caractéristiques. Il ne permet pas de formaliser des axiomes d'exclusion mutuelle ou d'implication (ex. *la présence d'un type de mouvement donné impose une configuration spécifique de la main*).

Absence de raisonnement automatique interprétable : Ni les réseaux sémantiques ni les modèles de *frames* ne disposent nativement d'un moteur d'inférence logique formel capable de vérifier la cohérence d'une combinaison de traits manuels et non-manuels.

Manque de standardisation et d'interopérabilité : Pour qu'un modèle sémantique soit exploitable à grande échelle, il doit s'adosser à un standard international permettant d'aligner les descriptions gestuelles avec des bases linguistiques externes.

2.4.3 L'émergence du Web Sémantique : De la donnée brute au sens formel

Face aux limites des modèles sémantiques classiques et à l'explosion des données non structurées, Tim Berners-Lee et ses collaborateurs ont formalisé au début des années 2000 la vision du **Web Sémantique** (*Semantic Web*). L'objectif fondamental de ce paradigme n'est plus seulement de présenter de l'information lisible par des humains, mais de **rendre la donnée interprétable et manipulable par des machines** de manière autonome.

Le Web Sémantique s'appuie sur une pile technologique normalisée par le W3C (*World Wide Web Consortium*) qui apporte une rigueur formelle inédite à la représentation des connaissances :

RDF (*Resource Description Framework*) : Le modèle de données de base du Web Sémantique, exprimant toute information sous forme de triplets (Sujet,Prédicat,Objet). Ce formalisme permet de décomposer toute connaissance complexe en un graphe orienté et étiqueté.

RDFS (*RDF Schema*) : Une extension de RDF fournissant un vocabulaire de base pour structurer les données en classes, sous-classes et propriétés, introduisant la notion d'héritage.

OWL (*Web Ontology Language*) : Le langage de modélisation le plus expressif de cette pile. Basé sur la logique de description (*Description Logics*), OWL permet de définir des contraintes complexes (équivalence, disjointure, cardinalité, transitivité) indispensables pour garantir un raisonnement rigoureux et sans ambiguïté.

SPARQL : Le langage de requête standardisé permettant d'interroger ces graphes de connaissances complexes de manière expressive et distribuée.

Dans le contexte du traitement automatique de la langue des signes, le Web Sémantique fournit un cadre d'interopérabilité universel : il permet de transformer des prédictions numériques (coordonnées squelettiques) en concepts RDF interconnectés et interprétables.

2.4.4 Synthèse : L'Ontologie OWL comme aboutissement pour l'IA Neuro-Symbolique

C'est précisément à l'intersection de ces limitations et des standards du Web Sémantique qu'intervient l'**Ontologie (OWL/W3C)**. En combinant la richesse structurelle des graphes, la précision des *frames*, et en y adjoignant une sémantique formelle basée sur la logique de description, l'ontologie s'impose comme l'aboutissement naturel des modèles sémantiques. Elle constitue l'outil idéal pour instancier un raisonnement neuro-symbolique explicable et rigoureux dans notre système de reconnaissance de l'U-ArSL.

2.5 L'Ontologie appliquée aux Langues des Signes

L'intégration des ontologies dans le domaine des langues des signes s'inscrit à l'intersection de la linguistique computationnelle, du Web Sémantique et de la vision par ordinateur. Cette section analyse les contributions majeures de la littérature afin d'identifier les limites que ce mémoire cherche à adresser.

2.5.1 Declerck et al. — La référence fondatrice

Les travaux menés par Thierry Declerck et ses collaborateurs (notamment issus du Centre de recherche allemand en intelligence artificielle - DFKI) s'inscrivent à la pointe de l'ingénierie des connaissances appliquées aux ressources linguistiques. Spécialistes des technologies du Web Sémantique et de la standardisation des lexiques informatiques, ces chercheurs ont été parmi les premiers à tenter de combler le fossé structurel entre les ontologies traditionnelles (pensées historiquement pour les langues vocales et écrites) et la complexité multidimensionnelle des langues des signes.

C'est dans ce contexte d'innovation théorique que leur travail [19], présenté à la conférence LREC sous le titre *«Towards a New Ontology for Sign Languages»*, constitue une référence fondamentale pour notre domaine. Ces auteurs y proposent une ontologie structurée spécifiquement autour des composantes phonologiques des signes, séparant formellement :

Les composantes manuelles : la configuration (*Handshape*), le mouvement (*Movement*), l'emplacement (*Location*) et l'orientation (*Orientation*).

Les composantes non-manuelles : l'expression faciale (*FacialExpression*), le mouvement de la tête (*HeadMovement*) et la posture corporelle (*BodyPosture*).

L'apport conceptuel central de cette recherche réside dans le passage d'un mappage direct et rudimentaire (Signe→Mot) à un modèle abstrait basé sur les concepts : Signe→Concept sémantique→Mots (traduisibles dans n'importe quelle langue), le tout rendu opérationnel par le framework W3C OntoLex-Lemon.

Toutefois, cette ontologie reste fondamentalement générique : conçue pour modéliser les langues des signes en théorie, elle n'a pas été instanciée ni validée pour la Langue des Signes Arabe (ArSL). De plus, les travaux ultérieurs de Declerck et de ses collègues [20] demeurent au niveau lexicographique pur : à notre connaissance, ils ne proposent pas d'instanciation sur des données vidéo réelles, ni de couplage avec un modèle de reconnaissance entraîné en apprentissage profond (vision par ordinateur), que ce soit pour l'ArSL, l'ASL, ou toute autre langue des signes.

2.5.2 Elsayed & Fathy — L'approche lexicale pour l'ArSL

Ce travail publié dans IJACSA constitue, parmi les travaux que nous avons consultés, la seule tentative combinant explicitement une ontologie avec un système de reconnaissance de l'ArSL. Les auteurs proposent un système hybride combinant un CNN pour reconnaître visuellement des signes arabes statiques et une ontologie multilingue (MSLO — *Multi Sign Language Ontology*) s'appuyant sur WordNet, obtenant 94,31 % de précision sémantique sur leur jeu de données et 88,87 % sur ArSL2018.

Tab. 2.3 : Une analyse critique de l'approche d'Elsayed & Fathy relève, d'après l'article, cinq limitations que ce mémoire cherche à adresser

Critère d'analyse	**Elsayed & Fathy (2020) — Limitation identifiée**	**Conséquence pour la reconnaissance**
Base de l'ontologie	WordNet (lexical)	Lie les signes à des mots, non à des composantes phonologiques.
Modalités analysées	Mains uniquement	Aucune prise en compte des expressions faciales ni de la posture.
Type de signes traités	Signes statiques (images fixes)	Inapte à capturer la dynamique temporelle des vidéos continuelles.
Structure interne	Non formalisée	Aucune décomposition en *Handshape*, *Movement*, *Location*, etc.
Analyse Manuel/Non-Manuel	Absente	Incapacité à lever les ambiguïtés sur des signes manuellement identiques.

La limitation fondamentale réside dans la nature de l'ontologie MSLO : il s'agit d'une **ontologie lexicale** (basée sur les mots et leurs synonymes) et non d'une **ontologie phonologique** (basée sur la structure interne du signe). Elle répond à la question « *ce signe signifie quels mots ?* » mais ne permet pas de répondre à « *comment ce signe est-il physiquement et linguistiquement structuré ?* ». C'est précisément cette seconde question que l'ontologie phonologique construite

dans ce mémoire adresse.

2.5.3 Clarification méthodologique et positionnement de notre contribution

Il convient de distinguer clairement notre approche des travaux théoriques antérieurs, notamment l'étude d'Ayça Müge Sevinç [21] intitulée *«An Event Based Ontology For Sign Language Phonology»*. Ce travail constitue un métamodèle théorique développé sous Protégé, visant uniquement à vérifier la cohérence structurelle et la validité formelle des signes (*well-formedness*) en s'appuyant sur des exemples de la langue des signes américaine (ASL). Il s'agit d'une ontologie abstraite qui n'a pas, à notre connaissance, été couplée à des modèles de vision par ordinateur ni appliquée à la langue des signes arabe.

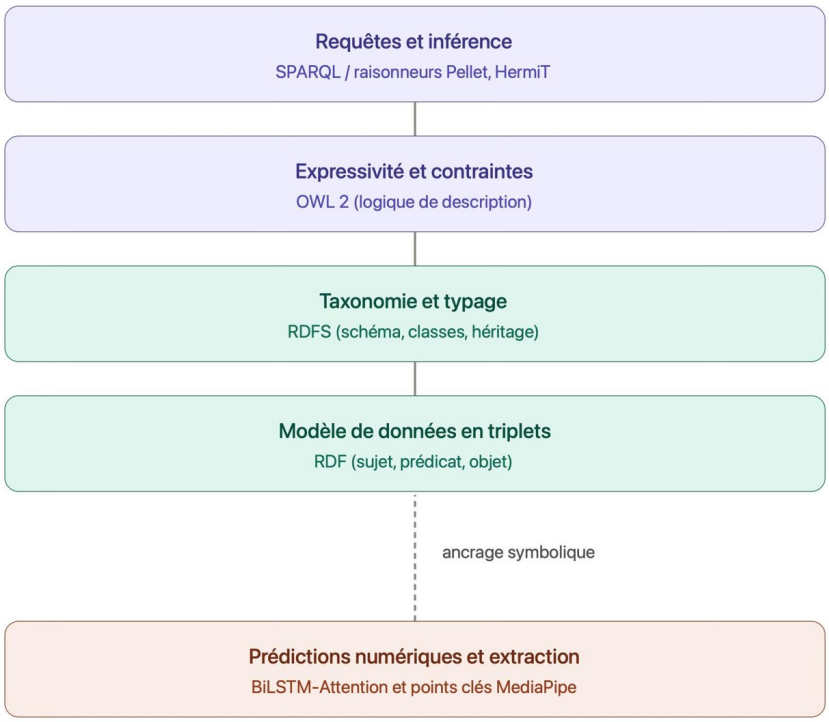


Fig. 2.1 : Pile technologique du Web sémantique (RDF, RDFS, OWL, SPARQL) ancrée sur les prédictions numériques du modèle neuro-symbolique.

À la croisée de la vision par ordinateur et des standards formels du Web Sémantique (représentés ci-dessus par la pile technologique du W3C allant du modèle RDF aux contraintes logiques complexes d'OWL), à notre connaissance, notre travail constitue une première tentative à :

Concevoir une ontologie OWL phonologique et sémantique spécifiquement dédiée à la Langue des Signes Arabe Unifiée (U-ArSL).

Le connecter, après la classification, à un pipeline d'apprentissage profond multimodal

(BiLSTM-Attention alimenté par les points clés MediaPipe), afin d'enrichir sémantiquement les prédictions du modèle.

2.5.4 Limites identifiées dans la littérature consultée

L'examen des travaux consultés sur la reconnaissance de l'ArSL fait apparaître trois limites récurrentes, que ces travaux ne semblent pas adresser conjointement. Cet examen n'est pas exhaustif : d'autres travaux, non consultés, peuvent exister.

Premièrement, à notre connaissance, aucune ontologie OWL formelle structurée autour des composantes phonologiques du signe (*Handshape*, *Movement*, *Location*, *FacialExpression*) n'a été proposée spécifiquement pour la langue des signes arabe. Deuxièmement, la contribution respective des composantes manuelles et non-manuelles dans la reconnaissance de l'ArSL ne fait l'objet d'aucune analyse comparative explicite dans les travaux examinés [8, 6, 5]. Troisièmement, il n'existe pas, dans la littérature consultée, de classification formelle des signes arabes selon leur type de dépendance modale (dominance manuelle, dépendance faciale, dépendance posturale).

Ce triple constat rejoint les conclusions d'Ibrahim et al. [7], qui soulignent, au terme de leur revue, que les systèmes actuels de reconnaissance présentent un biais méthodologique vers l'analyse des seuls gestes manuels, au détriment du rôle pourtant déterminant des expressions faciales et de la posture corporelle.

Tab. 2.4 : Positionnement de la contribution face aux limites des travaux consultés

Limite identifiée (travaux consultés)	**Réponse apportée**
Signe → Mot, sans structure [6, 5, 4]	Ontologie OWL : Signe → description phonologique → Concept
Données non annotées phonologiquement [7, 6]	Classes et propriétés OWL pour décrire Handshape, Movement, FacialExpression…
Fragmentation dialectale [8, 7]	Modélisation par concepts, indépendante de la variante lexicale
MSLO basée sur les mots, pas sur la phonologie [8]	Ontologie phonologique : structure interne du signe formalisée
Pas d'analyse quantitative manuel vs non-manuel (travaux consultés)	Étude d'ablation exploratoire (H1, H3, chapitre 5)

Cinq limites ont ainsi été identifiées à partir des travaux publiés consultés, sans prétendre à l'exhaustivité : l'absence de représentation phonologique formelle des signes, l'insuffisance des annotations dans les jeux de données existants, la fragmentation dialectale, la limitation de la principale ontologie ArSL identifiée [8] à une approche lexicale fondée sur WordNet, et l'absence d'analyse quantitative comparant l'apport des composantes manuelles et non-manuelles. La contribution de ce mémoire se positionne à l'intersection de la linguistique des langues des signes et de l'intelligence artificielle, avec un objectif : ne pas s'arrêter à l'étiquette du signe, mais lui associer une description de sa structure linguistique interne.

Le chapitre suivant détaille la méthodologie mise en œuvre : constitution du corpus, extraction multimodale via MediaPipe, architecture multi-branches et conception de l'ontologie OWL.

Chapitre 3

Analyse, méthodologie et conception

L'objectif de ce chapitre est de présenter la démarche scientifique et technique adoptée pour concevoir un système complet de reconnaissance de la langue des signes arabe (ArSL). Ce travail repose sur une approche neuro-symbolique qui combine la puissance de l'apprentissage profond multimodal (MediaPipe, BiLSTM, Attention) avec la rigueur d'une modélisation sémantique (ontologie OWL).

3.1 Analyse des besoins

L'analyse des besoins a été formalisée dans le cahier des charges (section 1.3) : les exigences fonctionnelles (Tableau 1.1) et techniques (Tableau 1.2) guident l'ensemble des choix présentés dans ce chapitre, à savoir la constitution du corpus (section 3.2), la sélection de l'extracteur de landmarks, du modèle temporel et de la stratégie de fusion (section 3.3), puis l'architecture hybride couplant le réseau neuronal à l'ontologie OWL (section 3.4).

3.2 Données et collecte sur le terrain

Ce jeu de données n'a pas été téléchargé sur Internet en un clic : c'est le fruit d'une année entière de travail sur le terrain. Il a fallu bâtir une relation de confiance avec la communauté des sourds, organiser des sessions d'enregistrement, ajuster les conditions de prise de vue et répéter patiemment chaque geste. Chaque fichier .npy stocké sur le disque représente des heures d'échange humain, de rigueur et d'engagement auprès des participants.

3.2.1 Constitution du corpus et distribution des classes

Caractérisation du jeu de données : assemblage d'un corpus original constitué de séquences de *landmarks* (.npy) couvrant les classes gestuelles retenues (un total de 356 séquences (286 en entraînement, 35 en validation et 35 en test).

Équilibre des classes : vérification de la répartition des enregistrements pour éviter tout biais d'apprentissage en faveur d'un signe particulier.

Tab. 3.1 : Caractéristiques du corpus et conditions d'acquisition

Caractéristique	Valeur
Nombre total de séquences	356
Nombre de classes	7
Séquences par classe	46 à 53 (moyenne 50,9)
Nombre de signeurs	10 enfants sourds
Âge des signeurs	8 à 14 ans
Répétitions par signe et par signeur	Environ 5
Nombre de sessions d'enregistrement	9
Dispositif de capture	Caméra Canon
Résolution et fréquence	1920×1080 (Full HD), 29,97 fps
Distance à la caméra	environ 1,5 m - 1,6m
Éclairage et arrière-plan	lumière naturelle, mur uni
Validation des séquences	Par un enseignant sourd, expert de l'U-ArSL
Critères d'exclusion	Séquences incomplètes ou mal exécutées, écartées après vérification par l'enseignant
Format	Landmarks pré-extraits (.npy), MediaPipe Holistic complet
Frames par séquence	Variable, 71 à 264 (moyenne 148,4, soit environ 5 s à 30 fps)
Dimension des features	1 662 par frame (pose 132 + main gauche 63 + main droite 63 + visage 1 404)

Tab. 3.2 : Distribution des séquences par classe

Classe	Nombre de séquences
PleaseComeIn	53
ThankYou	53
HowOldAreYou	52
PeaceBeUponYou	52
What'sYourName	50
WhatDoYouWant	50
HowAreYou	46
Total	**356**

3.3 Choix méthodologiques et technologiques

Trouver la bonne architecture a été un long processus d'essais et d'erreurs. Traiter directement des vidéos brutes demandait une puissance de calcul démesurée et manquait de précision sur les mouvements fins des doigts. Il a fallu décomposer le problème : isoler la géométrie du corps, donner de l'importance aux moments clés du geste, et traiter chaque canal d'expression (mains, visage, posture) indépendamment avant de les réunir.

Dans une recherche scientifique, le choix d'une technologie ne peut pas être arbitraire. Il doit répondre à trois critères : (1) la technologie est adaptée au problème posé, (2) elle est supérieure ou complémentaire aux alternatives comparables, et (3) son utilisation est validée

par la littérature récente dans un contexte similaire. Cette section justifie, selon ces trois critères, les quatre choix technologiques centraux de ce mémoire.

3.3.1 Pourquoi MediaPipe Holistic ?

Ce choix conditionne directement la validité de l'hypothèse **H1** : sans une extraction simultanée et cohérente des trois modalités (mains, visage, posture), il serait impossible de comparer objectivement un modèle multimodal complet à un modèle n'exploitant que les mouvements des mains. MediaPipe Holistic constitue ainsi le socle technique nécessaire pour tester empiriquement l'apport du multimodal.

Extraction squelettique compacte : conversion du flux vidéo en un ensemble de 543 *landmarks* 3D, réduisant la dimensionnalité tout en conservant la géométrie essentielle du geste.

Captation multimodale : prise en charge simultanée des composantes manuelles (mains) et non-manuelles (visage, buste), indispensables à la grammaire de la langue des signes.

Ce mémoire repose sur une question centrale (QR1) : dans quelle mesure l'ajout des expressions faciales et de la posture corporelle améliore-t-il la précision de reconnaissance ? MediaPipe Holistic est l'un des rares frameworks qui extraient simultanément et de manière cohérente les trois modalités dans le même pipeline temporel. Algethami et al. [6] l'utilisent pour extraire 258 points clés par frame et obtiennent 99,5 % de précision sur l'ArSL continu ; Alsharif et al. [5] le combinent à YOLOv11 et atteignent 98,2 % de mAP sur l'ASL. Sur le plan matériel, OpenPose nécessite un GPU dédié pour fonctionner en temps réel, alors que MediaPipe fonctionne sur CPU standard ,Ibrahim et al. [7] soulignent d'ailleurs que l'accessibilité du matériel est un critère de choix déterminant pour la recherche sur les langues des signes arabes.

MediaPipe Holistic est retenu parce qu'il fait partie des rares frameworks qui extraient les trois modalités simultanément, sur CPU standard, et qu'il a déjà été utilisé pour la reconnaissance de l'ArSL [6].

Tab. 3.3 : Les alternatives disponibles (caractéristiques générales)

Framework	**Modalités extraites**	**GPU requis ?**	**Temps réel sur CPU**	**Utilisé en ArSL***
MediaPipe Holistic	Mains + visage + corps	Non	Oui	Oui [6]
OpenPose	Mains + corps (visage partiel)	Recommandé	Limité	Non identifié
AlphaPose	Corps + mains (estimation)	Recommandé	Limité	Non identifié
Leap Motion	Mains uniquement (capteur dédié)	Non	Oui	Non identifié

3.3.2 Pourquoi BiLSTM avec Attention ?

Au-delà de son rôle dans la classification, le mécanisme d'attention constitue également l'instrument de test de l'hypothèse H4 : en pondérant dynamiquement les frames de la séquence, il permet de vérifier si les poids attribués coïncident effectivement avec les phases articulatoires clés du signe (transitions et tenues), rendant ainsi le processus de décision du modèle interprétable plutôt qu'opaque.

Fondements temporels et modélisation séquentielle

Dynamique temporelle bidirectionnelle : L'entrée du modèle est une séquence temporelle de points clés (*keypoints*) et non une image statique, ce qui exclut d'emblée les architectures conçues pour des images fixes (CNN classique, YOLO). Un signe interrogatif et un signe affirmatif peuvent partager la même configuration de main mais différer par une expression faciale évoluant dans le temps : seul un modèle temporel capture cette dynamique.

Focus attentionnel : Le mécanisme d'attention permet au modèle de concentrer son apprentissage sur les frames les plus significatives du signe, en ignorant les temps morts. Il complète la *Late Fusion* en mettant en évidence les instants temporels les plus pertinents dans chaque modalité, améliorant à la fois la performance globale et l'interprétabilité du système.

Analyse comparative des architectures de la littérature

Pour justifier rigoureusement ce choix face aux alternatives de l'état de l'art, une analyse comparative a été menée sur la base des travaux récents de la littérature :

Tab. 3.4 : Comparatif des architectures de modélisation spatio-temporelle

Architecture	**Adapté aux séquences ?**	**Petit corpus ?**	**Bidirectionnel ?**	**Résultat rapporté (autre corpus)**
BiLSTM + Attention	Oui	Adapté	Oui	99 % [6]
TCN	Oui	Plus de données souhaitables	Non	99,5 % [6]
GRU	Oui	Adapté	Selon variante	Peu documenté en ArSL
Transformer	Oui	Gros corpus requis	Oui	Bons résultats sur gros corpus
CNN seul	Non	Oui	Non	88,87 % [8]

Les résultats de la dernière colonne proviennent de corpus et de tâches différents du nôtre (ArSL continu pour [6], images statiques pour [8]) ; ils illustrent l'usage de chaque architecture dans la littérature et ne constituent pas une comparaison directe.

Synthèse des arguments de choix

Le choix de l'architecture **BiLSTM + Attention** repose sur quatre arguments :

- **Usage dans la littérature :** Algethami et al. [6] rapportent des performances proches pour le TCN (99,5 %) et le BiLSTM + Attention (99,0 %) sur leur corpus d'ArSL continu. Elsayed & Fathy [8] obtiennent 88,87 % avec un CNN sur des images statiques (ArSL2018), une configuration qui ne modélise pas la dynamique temporelle. Ces résultats, obtenus sur des corpus différents du nôtre, ne constituent pas une comparaison directe.
- **Adaptation aux petits corpus :** les Transformers, et dans une moindre mesure les TCN, sont généralement considérés comme plus exigeants en données. Un BiLSTM de taille modérée constitue un compromis raisonnable pour un corpus de quelques centaines de séquences.
- **Analyse de la multimodalité :** dans notre architecture, chaque branche (mains, visage, posture) possède sa propre couche d'attention, ce qui permet d'observer quelles frames sont privilégiées dans chaque modalité.
- **Test de l'hypothèse H4 :** le mécanisme d'attention fournit le cadre nécessaire pour examiner l'hypothèse H4.

3.3.3 Pourquoi Late Fusion ?

Au-delà d'un choix d'ingénierie, la fusion tardive constitue le cadre d'évaluation direct de l'hypothèse de recherche H2 : *la fusion tardive des modalités (mains, visage, posture) offre une meilleure capacité de discrimination que la fusion précoce (Early Fusion)*. La validation expérimentale de cette hypothèse fait l'objet d'un protocole dédié au Chapitre 5.

Fondements linguistiques et autonomie des modalités

Fondement linguistique : En linguistique des langues des signes [22], les composantes manuelles et non-manuelles remplissent des fonctions grammaticales distinctes. Les expressions faciales marquent la modalité de la phrase (ex : question, affirmation), tandis que la configuration des mains porte le contenu lexical. Traiter ces signaux dans des branches séparées respecte cette indépendance fonctionnelle.

Autonomie et stabilité représentationale : La séparation des branches évite que les repères à haute dimension du visage (1404 coordonnées) ne masquent la précision fine des configurations digitales de la main (63 coordonnées par main). Chaque branche spécialisée apprend sa propre dynamique temporelle avant l'intégration décisionnelle finale.

Analyse comparative des stratégies d'intégration multimodalité

Le choix du moment d'intégration dans le pipeline conditionne directement la capacité du modèle à extraire des descripteurs pertinents pour chaque canal :

Tab. 3.5 : Comparatif des stratégies d'intégration multimodale

Stratégie	Avantage	Problème
Early Fusion	Simple, un seul modèle	Déséquilibre dimensionnel : les features du visage (1 404 valeurs) dominent celles des mains (63 par main), pourtant plus discriminantes.
Late Fusion (retenue)	Chaque branche apprend sa propre dynamique temporelle	Plus complexe à implémenter

Synthèse des arguments de choix

L'adoption de la **Late Fusion** repose sur trois arguments complémentaires :

Adéquation linguistique : Alignement strict avec la structure phonologique et syntaxique de la langue des signes [22].

Preuve empirique dans la littérature : Les travaux d'Elsayed & Fathy [8] démontrent empiriquement qu'une architecture à plusieurs niveaux de traitement spécialisés améliore la précision (+5.44%) par rapport à un traitement monolithique.

Alignement avec le plan d'expérience (H2) : Fourniture du cadre architectural nécessaire pour comparer rigoureusement l'Efficacité relative de l'Early vs Late Fusion au Chapitre 5.

3.3.4 Pourquoi TensorFlow/Keras avec Python ?

Le choix de l'environnement de développement et de la bibliothèque d'apprentissage profond conditionne la flexibilité de l'architecture, la reproductibilité des expériences et la facilité d'intégration dans un pipeline neuro-symbolique.

Flexibilité architecturale et écosystème MLOps

Mise en œuvre d'architectures multi-entrées : L'API fonctionnelle de Keras facilite la construction de réseaux complexes à branches parallèles (pose, mains, visage), indispensable pour implémenter la *Late Fusion* et injecter des couches d'attention personnalisées.

Compatibilité et reproductibilité : MediaPipe et TensorFlow s'intègrent facilement dans un même pipeline Python, sans infrastructure matérielle propriétaire.

Analyse comparative des environnements matériels et logiciels

Le tableau ci-dessous synthétise le positionnement de TensorFlow/Keras par rapport aux alternatives de l'état de l'art :

Tab. 3.6 : Comparatif des frameworks pour le développement du modèle

Critère	TensorFlow/Keras	PyTorch	Scikit-learn
Support BiLSTM	Natif	Natif	Non

Modèles multi-branches	API fonctionnelle simple	Possible (code plus détaillé)	Non
Intégration MediaPipe	Via NumPy	Via NumPy	Via NumPy
Environnement (VS Code / Colab)	Local et cloud	Local et cloud	Local et cloud
Utilisé dans les articles lus	[8, 7]	[6]	Non

3.3.5 Cohérence globale et matrice de justification des choix d'architecture

Pour conclure la justification des choix méthodologiques, le tableau synthétique ci-dessous récapitule les arbitrages technologiques majeurs effectués dans ce travail, les alternatives rejetées et les preuves empiriques qui les étayent dans la littérature :

Tab. 3.7 : Matrice de justification des choix d'architecture

Choix	**Alternative écartée**	**Raison**	**Appui**
MediaPipe Holistic	OpenPose	GPU recommandé, visage partiel	Usage en ArSL [6] et en ASL [5]
BiLSTM + Attention	TCN	Plus exigeant en données ; performances proches rapportées	[6] (BiLSTM 99 % ; TCN 99,5 %, autre corpus)
BiLSTM + Attention	CNN seul	Ne modélise pas la dynamique temporelle	[8] (images statiques)
Late Fusion	Early Fusion	Les features du visage (1 404) dominent celles des mains (63 par main)	Cadre conceptuel [16] ; comparaison Exp1 vs Exp2 (chapitre 5)
TensorFlow/Keras	PyTorch	API fonctionnelle adaptée aux modèles multi-branches	[8, 7]

Synthèse : ces quatre choix forment un ensemble cohérent :

- **MediaPipe** extrait les caractéristiques des trois modalités avec un coût de calcul modéré ;
- **BiLSTM + Attention** modélise la dynamique temporelle et rend observables les frames privilégiées par le modèle (test de H4) ;
- **Late Fusion** préserve l'autonomie des canaux et fournit le cadre de comparaison avec l'Early Fusion (test de H2) ;
- **TensorFlow / Keras** assure la mise en œuvre de l'ensemble du pipeline.

3.4 Architecture de la solution

Un réseau de neurones seul reste une boîte noire qui prédit des probabilités. Mais dans une langue, un geste a du sens, une grammaire et des règles. L'enjeu de cette étape a été d'associer

la puissance de calcul du deep learning à une ontologie sémantique, afin de faire le pont entre la prédiction statistique et la compréhension réelle du langage.

3.4.1 Architecture globale du système

Le pipeline complet suit la chaîne suivante : collecte des données → vidéo d'entrée → MediaPipe Holistic (extraction des *landmarks*) → séparation en quatre modalités (pose, main gauche, main droite, visage) → traitement indépendant par branche (masquage → projection dense → BiLSTM → attention → dropout) → Late Fusion (concaténation des représentations) → dense + softmax (classification) → mapping vers l'ontologie OWL → sortie structurée.

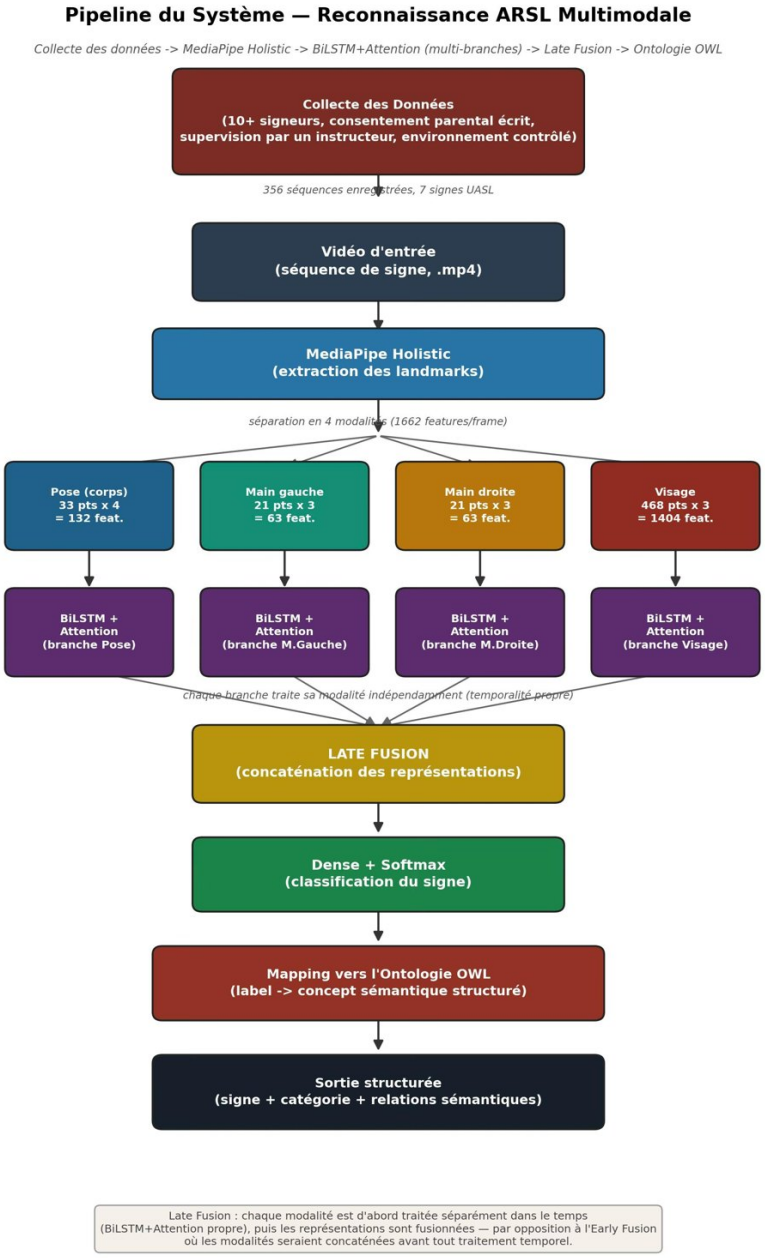


Fig. 3.1 : Pipeline du système de reconnaissance ArSL multimodal.

3.4.2 Spécialisation des branches multimodales

Branche Pose : analyse de la dynamique globale du buste et des bras.

Branches Mains : modélisation fine des 21 articulations de chaque main pour capturer les configurations digitales (*handshape*).

Branche Visage : prise en compte des expressions faciales (sourcils, bouche) pour

l'intonation non-manuelle.

3.4.3 Mécanisme d'attention et BiLSTM

Le réseau bidirectionnel extrait le contexte temporel de chaque séquence :

$$h_t = \left[\overrightarrow{\text{LSTM}}(x_t) \parallel \overleftarrow{\text{LSTM}}(x_t)\right]$$

Le mécanisme d'attention, dans sa formulation hiérarchique proposée par Yang et al. [23], projette d'abord chaque état caché h_t à travers une couche cachée afin d'obtenir sa représentation :

$$u_t = \tanh\left(W_w h_t + b_w\right)$$

Cette représentation est ensuite comparée à un vecteur de contexte appris u_w.

Le mécanisme d'attention pondère ensuite chaque état caché afin de produire le vecteur de contexte v :

$$\alpha_t = \frac{\exp\left(u_t^T u_w\right)}{\sum_{t'} \exp\left(u_{t'}^T u_w\right)}$$

puis :

$$v = \sum_t \alpha_t h_t$$

où α_t représente le poids d'attention attribué au pas de temps t, et la somme de tous les poids d'attention est normalisée par la fonction Softmax :

$$\sum_t \alpha_t = 1$$

3.4.4 Fusion tardive (Late Fusion) et décision

- **Agrégation :** concaténation des représentations V :

$$V_{\text{fusion}} = [V_{\text{pose}} \parallel V_{\text{main_g}} \parallel V_{\text{main_d}} \parallel V_{\text{visage}}]$$

- **Inférence :** passage par des couches denses avec Dropout, puis classification finale via une fonction Softmax.

3.4.5 Modélisation ontologique en OWL

L'ontologie OWL construite (sign_language_ontology.owl), développée dans Protégé, modélise chaque signe selon un modèle phonologique linguistique fondé sur les travaux

fondateurs de Stokoe [24], qui établit le premier que le signe se décompose en unités phonologiques distinctes , puis développé par le *Movement-Hold Model* de Liddell & Johnson.

Analyse phonologique des signes du corpus

Afin de servir de base à la modélisation ontologique, une analyse linguistique explicite a été menée sur les 7 signes constituant le corpus expérimental. Le **Tableau 3.8** détaille la structure (simple ou composée) et le résumé des composantes phonologiques (forme de la main, emplacement, mouvement) pour chaque signe.

Tab. 3.8 : Description phonologique des 7 signes du corpus U-ArSL

Signe	Structure	Résumé phonologique
ThankYou	Simple, 1 main	Main droite plate, doigts collés : touche le côté du front (tempe) puis s'éloigne vers l'avant.
HowAreYou	Simple, 2 mains	Deux mains : ouverture des mains paumes vers le haut vers l'avant, deux pouces vers le haut près de la poitrine.
PleaseComeIn	Simple, 2 mains	Deux mains ouvertes, paumes vers le haut : mouvement balayé de la droite vers la gauche devant le corps avec un visage accueillant.
HowOldAreYou	Composé, 3 phases	Pointage → paume sur poitrine → mouvement circulaire interrogatif
PeaceBeUponYou	Composé, 3 phases	Main droite en 3 phases : salut au front → fermeture en poing → main à plat balayée
WhatDoYouWant	Composé, 3 phases	Paume vers le haut → tirée au cou → inclinaison interrogative
What'sYourName	Composé, 3 phases	Index pointé → mouvement circulaire → tapotement sur poitrine

Implémentation de la hiérarchie et des propriétés OWL

À partir de cette décomposition phonologique, la structure formelle a été implémentée dans Protégé :

Hiérarchie de classes : Thing → Sign | Concept | PhonologicalFeature, où PhonologicalFeature → Handshape | Movement | Location | FacialExpression.

Object Properties : hasHandshape, hasMovement, hasLocation, hasOrientation, hasFacialExpression, hasHeadMovement, hasBodyPosture, representsConcept, complétées par des propriétés de composition (isCompound, isTwoHanded).

Questions de compétence ayant guidé la conception : Quel est le concept sémantique associé à un signe donné ?

Quels signes appartiennent à la même catégorie sémantique ?

Un signe a-t-il des synonymes ou des variantes régionales dans le corpus ?
Quelle est la relation entre un signe et sa traduction en arabe standard ou en français ?

Tab. 3.9 : Instanciation OWL de l'individu Sign_ThankYou

Propriété OWL	**Valeur (individu)**
hasHandshape	Flat_hands_Open
hasMovement	Forward_Movement
hasLocation	Forehead
hasOrientation	PalmSideways
hasFacialExpression	Smile
representsConcept	Thank_You

Ces valeurs correspondent à l'individu `Sign_ThankYou` de l'ontologie (capture Protégé : Figure D.2, Annexe D).

Ce niveau de description phonologique n'apparaît pas dans l'ontologie MSLO d'Elsayed & Fathy [8] ni dans les autres travaux ArSL consultés (chapitre 2) ; il constitue une contribution originale de ce mémoire. En liant les signes à des concepts neutres linguistiquement plutôt qu'à des mots arabes spécifiques via le framework OntoLex-Lemon, la représentation devient de plus indépendante des variantes dialectales , un même concept pouvant être relié à des réalisations lexicales en arabe égyptien, arabe standard, français ou anglais.

3.5 Conclusion du chapitre

Ce chapitre a présenté le corpus, justifié les choix méthodologiques et technologiques (MediaPipe Holistic, BiLSTM avec attention, Late Fusion, TensorFlow/Keras) et décrit l'architecture de la solution ainsi que la modélisation ontologique OWL. Le chapitre suivant détaille leur mise en œuvre et le protocole expérimental.

Chapitre 4

Réalisation et protocole expérimental

4.1 Environnement de travail

Les expériences ont été réalisées localement sur un MacBook Air (puce Apple M4, 16 Go de mémoire, macOS 26.3.1) avec Python 3.11, TensorFlow 2.16.1 / Keras 3.15.0, MediaPipe 0.10.14, NumPy, Pandas, Scikit-learn et rdflib ; l'ontologie est éditée avec Protégé. Le code source et l'ontologie sont disponibles dans le dépôt cité en Annexe A ; les versions complètes des bibliothèques et l'organisation du projet figurent en Annexe C.

4.2 Mise en œuvre des données

4.2.1 Prétraitement et normalisation des landmarks

Normalisation spatiale : centrage et mise à l'échelle des coordonnées (x, y, z) par rapport à des repères anatomiques fixes (centre des épaules), rendant le modèle invariant à la taille et à la position du signeur.

Tenseurs d'entrée : organisation des données sous forme de matrices temporelles (T, D) adaptées aux réseaux récurrents.

4.2.2 Harmonisation temporelle (padding et masquage)

Égalisation des durées : application d'un *padding* à zéro pour amener toutes les séquences à une longueur uniforme T_max.

Couche de masquage : configuration du réseau pour ignorer automatiquement les valeurs de remplissage pendant le calcul des gradients.

4.2.3 Découpage et protocole d'évaluation

Découpage stratifié : effectué par classe avec une graine fixe (seed = 42) pour la reproductibilité, avec exactement 5 séquences par classe en validation et en test (répartition approximative 80 % / 10 % / 10 %, Tableau 4.1).

Indépendance vis-à-vis des signeurs : le découpage étant aléatoire et stratifié par classe, il ne garantit pas que toutes les séquences d'un même signeur soient affectées à un seul ensemble.

L'évaluation rapportée est donc de type intra-signeurs, potentiellement plus favorable qu'une évaluation sur des signeurs inconnus. Une validation *Leave-One-Signer-Out* constitue une étape prioritaire des travaux futurs.

Point de vigilance méthodologique : le jeu de test n'est utilisé qu'une seule fois, à la toute fin de chaque configuration expérimentale, pour éviter toute fuite d'information dans le processus de sélection de modèle.

Tab. 4.1 : Répartition stratifiée du jeu de données

Ensemble	Nb séquences	Par classe
Entraînement	286	36 à 43
Validation	35	5
Test	35	5
Total	**356**	46 à 53

Positionnement du travail : **Positionnement du travail :** avec seulement 35 séquences de test (5 par classe), chaque erreur de classification fait varier l'accuracy globale d'environ 2,9 points. À titre d'exemple, l'accuracy de 97,1 % obtenue par le modèle retenu correspond à un intervalle de confiance à 95 % compris entre 85,5 % et 99,5 % (méthode de Wilson). Ce mémoire se positionne donc explicitement comme une **preuve de concept** (*proof of concept*), illustrant la faisabilité d'une méthodologie sur un corpus restreint, et non comme une mesure de performance généralisable à grande échelle. L'extension future du corpus et une validation inter-signeurs permettront de renforcer la portée statistique des résultats.

4.3 Implémentation des modèles

Le modèle retenu (Exp1) reçoit des séquences de landmarks MediaPipe Holistic tronquées ou complétées à 150 frames (1 662 valeurs par frame). Il comporte quatre branches (pose, main gauche, main droite, visage), chacune composée d'un BiLSTM suivi d'un mécanisme d'attention ; leurs représentations sont concaténées (Late Fusion, section 3.4) puis traitées par des couches denses avec Dropout et une fonction Softmax. Il compte 148 907 paramètres entraînables et bénéficie d'une régularisation renforcée (Dropout de 0,4 à 0,5, régularisation L2, EarlyStopping ; Tableau 5.4). Le découpage des données est reproductible (graine fixée à 42), alors que l'initialisation des poids ne l'est pas : les modèles entraînés de chaque expérience ont donc été conservés afin de pouvoir réévaluer les résultats sans réentraînement. La fiche descriptive complète du modèle (*Model Card*) figure en Annexe C et les extraits de code essentiels en Annexe A.

4.3.1 Intégration de la couche sémantique (ontologie)

Interfaçage : Connexion entre les sorties de prédiction de Keras et le moteur de traitement via la bibliothèque rdflib. Conformément à la stratégie définie, l'ontologie est appliquée en post-traitement : le label prédit par le modèle est relié à un individu Sign_X de l'ontologie, sans intervenir dans le calcul de la prédiction elle-même. L'accuracy du système global reste donc strictement celle mesurée lors de l'expérience de référence (Exp1, soit 97,1%).

Mécanisme d'interrogation de l'ontologie : Le script predict.py (Annexe A) effectue une requête directe sur le graphe RDF via rdflib. Le label prédit par la couche Softmax est normalisé (suppression de la ponctuation et des espaces), puis comparé aux rdfs :label des individus de la classe Sign. Une fois l'individu correspondant identifié, l'ensemble de ses assertions de propriétés (hasHandshape, hasLocation, hasMovement, hasOrientation, hasFacialExpression, representsConcept) est extrait par parcours du graphe.

Précision méthodologique importante : Ce mécanisme constitue une requête directe sur les triplets RDF (*triple matching*), et non une inférence par un raisonneur OWL (*DL reasoner*) au sens strict. Aucune règle d'inférence logique (subsomption de classes, propriétés transitives ou symétriques) n'est exécutée à ce stade : le système récupère des faits explicitement présents dans l'ontologie, sans en déduire de nouveaux.

Perspectives d'inférence : L'intégration d'un raisonneur complet (par exemple via la bibliothèque Owlready2 avec le raisonneur Pellet ou HermiT) constitue une piste de travail future pertinente, notamment pour exploiter le framework OntoLex-Lemon et inférer automatiquement des relations sémantiques non explicitement assertées (synonymie translinguistique, appartenance à une catégorie parente).

Validation contextuelle : Cette couche permet de vérifier les contraintes ontologiques pour enrichir le signe reconnu avec sa définition sémantique complète, transformant une prédiction numérique brute en connaissance interprétable (Tableau 4.2).

Tab. 4.2 : Comparaison de la structure de sortie sans et avec enrichissement ontologique

Sans ontologie	Avec ontologie
`ThankYou`	`{signe: ThankYou, handshape: Flat_hands_Open, location: Forehead, movement: Forward_Movement, concept: Thank_You}`

Remarque : cette sortie simplifiée reprend cinq éléments de l'individu `Sign_ThankYou` (Tableau 3.9). Les propriétés `hasOrientation` (PalmSideways) et `hasFacialExpression` (Smile) figurent aussi dans l'ontologie mais ne sont pas reprises dans cet exemple.

4.4 Protocole expérimental

Métriques retenues : accuracy, F1-score macro (essentiel vu le corpus limité), matrice de confusion, latence d'inférence. Quatre expériences ablatives ont été planifiées en amont pour tester les hypothèses H1 à H5, avec un baseline de référence (Exp1) et la règle stricte de non-contamination du test set.

4.5 Déploiement

Le système est livré sous forme de prototype de recherche : un script de prédiction (`predict.py`) et une interface de démonstration (`app.py`), décrits en Annexe A. Il n'est pas destiné à un usage en production (Annexe C) et aucun déploiement en production n'a été réalisé dans le cadre de ce travail ; le déploiement sur dispositifs mobiles est abordé dans les perspectives.

4.6 Difficultés rencontrées

La principale difficulté technique a été le surapprentissage observé en Phase 1 avec le modèle de 934K paramètres, résolu par l'architecture réduite et régularisée de la Phase 2 (section 5.7.6). Par ailleurs, la troncature des séquences à 150 frames a pu contribuer à l'unique erreur de classification observée (section 5.8).

Le chapitre suivant présente le protocole expérimental complet et les résultats obtenus avec cette architecture, en testant successivement chacune des hypothèses formulées au chapitre 1.

Chapitre 5

Résultats et discussion

Ce chapitre présente l'évaluation expérimentale de l'architecture proposée pour la reconnaissance de la Langue des Signes Arabe Unifiée (U-ArSL). Les expériences examinent les hypothèses de recherche énoncées au chapitre 1 (**H1** à **H5**). Toutes les conclusions de ce chapitre sont limitées aux conditions expérimentales décrites aux chapitres 3 et 4 : un corpus de 356 séquences, un découpage unique stratifié par classe, une seule initialisation et un jeu de test de 35 séquences.

5.1 Modèle retenu : Holistic + Late Fusion + Attention (Exp1)

Le modèle retenu (désigné par **Exp1**) repose sur une architecture à quatre branches (main droite, main gauche, visage, posture corporelle) fusionnées selon une stratégie de fusion tardive (*Late Fusion*), avec un mécanisme d'attention temporelle dans chaque branche. Le modèle totalise **148 907 paramètres entraînables** (environ 149K), avec une régularisation renforcée (Dropout de 0,4 à 0,5, régularisation L2 et *EarlyStopping*).

L'entraînement a été réalisé sur 286 séquences, le suivi de l'entraînement sur 35 séquences de validation, et l'évaluation finale porte sur un jeu de test stratifié de 35 séquences.

5.1.1 Performances globales du modèle Exp1

Tab. 5.1 : Métriques globales d'évaluation du modèle retenu (Exp1)

Métrique (jeu de test, 35 séquences)	**Valeur**
Accuracy	0,971 (34/35)
IC à 95 % (Wilson)	[0,855 ; 0,995]
F1-score macro	0,971
Précision macro	0,976
Rappel macro	0,971

L'intervalle de confiance montre qu'avec 35 séquences de test, une accuracy observée de 97,1 % reste compatible avec une performance réelle comprise approximativement entre 85 %

et 99 %. Les courbes d'apprentissage (Annexe C) montrent des pertes d'entraînement et de validation qui évoluent de manière proche, sans divergence marquée entre les deux au cours de l'entraînement.

5.1.2 Performances détaillées par classe gestuelle

Le Tableau 5.2 présente la décomposition des performances pour les 7 classes du corpus U-ArSL.

Tab. 5.2 : Performances par classe du modèle retenu (Exp1, jeu de test)

Classe	Précision	Rappel	F1-score
HowAreYou	1,000	1,000	1,000
HowOldAreYou	1,000	0,800	0,889
PeaceBeUponYou	0,833	1,000	0,909
PleaseComeIn	1,000	1,000	1,000
ThankYou	1,000	1,000	1,000
What'sYourName	1,000	1,000	1,000
WhatDoYouWant	1,000	1,000	1,000

Cinq des sept classes obtiennent un F1-score de 1,000 sur le jeu de test.

L'unique erreur concerne une séquence HowOldAreYou prédite comme PeaceBeUponYou (rappel de 0,800 pour HowOldAreYou, avec seulement 5 séquences de test par classe). La matrice de confusion complète figure en Annexe C.

5.2 Études d'ablation

Pour évaluer la contribution spécifique de chaque composant architectural et vérifier empiriquement les hypothèses de recherche, Trois expériences d'ablation ont été menées (Exp2, Exp3, Exp4), chacune modifiant un composant du modèle retenu (Tableau 5.3).

Tab. 5.3 : Synthèse des études d'ablation (jeu de test, 35 séquences)

Exp.	Configuration	Accuracy	IC 95 % (Wilson)	F1 macro	Écart vs Exp1
Exp1 (retenu)	Holistic, Late Fusion, Attention	0,971	[0,855 ; 0,995]	0,971	—
Exp2	Holistic, Early Fusion (projection d=32), Attention	0,771	[0,610 ; 0,879]	0,767	−20,0 pts
Exp3	Mains seules, Late Fusion, Attention	0,543	[0,382 ; 0,695]	0,518	−42,8 pts
Exp4	Holistic, Late Fusion, sans Attention	0,829	[0,673 ; 0,919]	0,803	−14,2 pts

5.2.1 Apport de la Multimodalité Holistique (Exp3— Test de H1)

La suppression des modalités non-manuelles (visage et posture corporelle) entraîne la dégradation la plus sévère enregistrée lors des expérimentations, avec une chute d'accuracy de 42,8 points. L'examen de la matrice de confusion de l'Exp3 montre des confusions massives entre des signes dont la configuration manuelle est similaire mais dont l'intonation faciale ou l'orientation du buste diffère.

Conclusion sur H1 : L'hypothèse **H1 est soutenue dans les conditions de ce corpus**. L'intégration conjointe des expressions faciales et de la posture corporelle améliore nettement la précision de reconnaissance par rapport à un modèle n'exploitant que les mouvements des mains (écart de 42,8 points entre Exp1 et Exp3, sur 35 séquences de test et une seule initialisation aléatoire).

5.2.2 Évaluation de la Stratégie de Fusion (Exp2 — Test de H2)

La tentative initiale d'Early Fusion par simple concaténation brute des repères (*landmarks*) au niveau des entrées a provoqué un échec d'apprentissage (*accuracy* $\approx$20 %, à comparer au niveau de hasard de 14,3 % pour 7 classes). En raison de la prédominance numérique des repères faciaux (1404 variables sur 1662, soit 84.5%), le signal discriminant des mains s'est retrouvé numériquement neutralisé.

Après application d'une correction méthodologique , projection linéaire intermédiaire de chaque modalité dans un espace vectoriel de dimension commune (d=32) avant concaténation , le modèle Early Fusion atteint 77.1%d'accuracy.

Conclusion sur H2 : L'hypothèse **H2 est soutenue dans les conditions de ce corpus**. La stratégie de fusion tardive (*Late Fusion*) surpasse l'Early Fusion corrigée de 20,0 points de précision, ce qui suggère qu'elle préserve mieux la spécificité de chaque flux d'information avant la décision finale (les capacités des deux modèles n'étant pas égalisées).

5.2.3 Analyse par Typologie des Signes (Test de H3)

L'analyse comparative de l'Exp1 et de l'Exp3 révèle une sensibilité hétérogène des signes face à l'ablation des composantes non-manuelles : **Signes dépendants du visage/corps :** Les phrases interrogatives et les salutations gestuellement proches subissent la chute la plus sévère dans l'Exp3 (par exemple, effondrement des performances sur HowAreYou et PeaceBeUponYou).

Signes dominés par les mains : Les signes possédant une configuration manuelle très spécifique conservent un taux de reconnaissance acceptable même sans canal facial.

Conclusion sur H3 : L'hypothèse **H3 est partiellement soutenue**. La baisse est forte pour deux des signes interrogatifs mais faible pour les deux autres, et la baisse moyenne est

comparable (questions $-0{,}46$, autres $-0{,}44$) : l'apport du multimodal n'apparaît donc pas uniformément plus marqué pour les signes dépendant de composantes non manuelles.

5.2.4 Rôle de l'Explicabilité Temporelle et de l'Attention (Exp4 — Test de H4)

L'ablation du mécanisme d'attention spatio-temporelle induit une baisse d'accuracy de 14,2 points (accuracy de 82,9 %). Sans attention, la confusion se concentre sur les classes HowOldAreYou et ThankYou.

L'analyse des poids d'attention extraits de l'Exp1 confirme que le modèle attribue des coefficients élevés (jusqu'à 0.85) aux frames correspondant aux phases articulatoires clés (tenue du signe et apex de l'expression faciale), délaissant les mouvements de transition.

Conclusion sur H4 : L'hypothèse **H4 est soutenue dans les conditions de ce corpus**. Le mécanisme d'attention identifie les frames les plus discriminantes au cours de l'exécution, renforçant la précision et l'interprétabilité de la décision.

5.3 Hiérarchie d'impact des facteurs d'architecture

La comparaison croisée des études d'ablation permet de formaliser la hiérarchie de dominance des choix de conception pour la reconnaissance holistique de la langue des signes :

1. Choix des Modalités (H1) — Impact : $-$**42.8 pts**

↪ *La complétude informationnelle (Mains + Visage + Corps) est le facteur le plus critique.*

⇓

2. Stratégie de Fusion (H2) — Impact : $-$**20.0 pts**

↪ *La fusion tardive (Late Fusion) préserve la richesse de chaque modalité par rapport à l'Early Fusion.*

⇓

3. Mécanisme d'Attention (H4) — Impact : $-$**14.2 pts**

↪ *L'attention temporelle affine la décision en ciblant les frames clés (apex).*

Cette hiérarchisation constitue un résultat **indicatif** de ce travail : elle suggère que la complétude informationnelle en entrée (multimodalité) pèse davantage que la stratégie d'intégration vectorielle, qui pèse elle-même davantage que le mécanisme d'attention spatio-temporel. Ce classement H1 $>$ H2 $>$ H4 repose sur seulement 35 séquences de test et sur une seule initialisation aléatoire par configuration ; il doit être confirmé par des répétitions et par une évaluation inter-signeurs.

5.4 Évaluation de la Robustesse Architecturale — Comparaison Phase 1 vs Phase 2 (Test de H5)

Afin d'évaluer la capacité de généralisation d'une architecture à paramétrage réduit face à un modèle de forte capacité, les performances de l'Exp1 sont mises en perspective avec le modèle de référence antérieur (Phase 1).

Tab. 5.4 : Comparaison de la robustesse architecturale (Phase 1 vs Phase 2)

Dimension d'analyse	**Modèle de Référence — Phase 1**	**Modèle Retenu (Exp1) — Phase 2**
Architecture	Single-stream (forte capacité)	Multi-branches (Late Fusion)
Nombre de paramètres	**934 215**	**148 907** (réduction de 84 %)
Régularisation	Dropout unique (0.2)	Dropout renforcé (0.4–0.5), L2 , EarlyStopping
Comportement à l'entraînement	Surapprentissage marqué (*Overfitting*)	Courbes Train/Val proches (pas de surapprentissage marqué observé sur les courbes présentées)
Accuracy obtenue	91.3% (sur 9 classes)	**97.1%** (sur 7 classes)

Remarque méthodologique : Cette comparaison présente un caractère indicatif du fait d'une légère différence de périmètre applicatif (9 classes en Phase 1 vs 7 classes en Phase 2). Cette tendance doit donc être interprétée avec prudence.

Conclusion sur H5 : Les résultats sont **indicatifs** pour H5. L'architecture multi-branches à paramétrage réduit (149K) associée à une régularisation renforcée ne présente plus la divergence entre pertes d'entraînement et de validation observée avec le modèle single-stream (934K). Toutefois, la comparaison modifie plusieurs facteurs à la fois (nombre de classes, architecture, régularisation) et ne permet pas d'isoler l'effet de chacun.

5.5 Analyse de l'Erreur de Classification (Couplage Neuro-Symbolique)

L'unique erreur de classification observée sur le jeu de test de l'Exp1 (HowOldAreYou prédit comme PeaceBeUponYou) a fait l'objet d'un audit diagnostique approfondi à la croisée du numérique et du symbolique.

5.5.1 Explication phonologique et ontologique (Couche Symbolique)

La consultation des assertions phonologiques au sein de l'ontologie OWL créée au Chapitre 3 met en évidence la proximité structurelle des deux signes : Les deux signes sont des signes

composés (`isCompound` = true), exécutés principalement avec une seule main (`isTwoHanded` = false), dont la phase initiale place la main près du buste ou du visage (`hasLocation`).

5.5.2 Explication technique et post-hoc (Pipeline de Données)

L'inspection de la séquence vidéo source incriminée a révélé une piste liée au prétraitement : la vidéo comptait **187 frames**, dépassant le seuil de troncature maximale (Tmax = 150 frames). La troncature automatique a pu éliminer la phase finale de la vidéo, qui contient le mouvement circulaire et l'expression interrogative caractéristiques du signe HowOldAreYou ; la séquence tronquée ne présenterait alors que la phase initiale, proche de celle de PeaceBeUponYou. Cette explication reste plausible mais n'a pas été vérifiée expérimentalement.

Ce diagnostic illustre la valeur ajoutée du couplage neuro-symbolique : l'ontologie permet d'expliciter la proximité conceptuelle dans l'espace latent, tandis que l'analyse du pipeline isole le biais technique d'acquisition.

5.6 Synthèse des résultats et statut des hypothèses

Tab. 5.5 : Statut des hypothèses de recherche (H1–H5) dans les conditions de ce corpus

Code	Hypothèse	Statut	Éléments expérimentaux
H1	L'ajout du visage et de la posture améliore la précision.	Soutenue (corpus actuel)	Écart de 42,8 points entre Exp1 et Exp3 ; contributions du visage et de la posture non isolées.
H2	La Late Fusion est plus efficace que l'Early Fusion.	Soutenue (corpus actuel)	Écart de 20,0 points entre Exp1 et Exp2 ; capacités des modèles non égalisées.
H3	Les signes dépendant des composantes non-manuelles bénéficient le plus du multimodal.	Partiellement soutenue	Baisse forte pour deux questions, faible pour les deux autres ; baisse moyenne comparable (questions $-0{,}46$, autres $-0{,}44$).
H4	L'attention attribue des poids plus élevés aux frames clés (tenues et apex).	Soutenue (corpus actuel)	Écart de 14,2 points entre Exp1 et Exp4 ; inspection qualitative des poids d'attention.
H5	Une architecture réduite et régularisée présente moins de surapprentissage.	Indicative	Comparaison Phase 1 / Phase 2 avec plusieurs facteurs modifiés (nombre de classes, architecture, régularisation).

La section suivante propose une mise en perspective critique des résultats obtenus en examinant le rôle exact de chaque composant architectural, l'apport explicatif de l'ontologie et le comportement du modèle face aux contraintes de la Langue des Signes Arabe (U-ArSL), tout en exposant en toute transparence les limites méthodologiques du travail.

5.7 Discussion

Ce chapitre propose une analyse critique et une mise en perspective approfondie des résultats expérimentaux présentés au Chapitre 5. L'objectif est de dépasser la simple lecture des métriques pour interpréter le comportement de notre architecture neuro-symbolique au regard des enjeux linguistiques de la Langue des Signes Arabe Unifiée (U-ArSL) et des travaux existants de la littérature.

5.7.1 Synthèse au regard des hypothèses

Les quatre expériences d'ablation menées à la section 5.2 fournissent des éléments empiriques indicatifs relatifs aux hypothèses de recherche formulées en amont (H1 à H5).

Un résultat scientifique majeur de cette évaluation réside dans la **hiérarchie d'impact** observée entre les trois facteurs architecturaux testés :



Fig. 5.1 : Ordre d'impact des facteurs étudiés : écart d'accuracy par rapport à Exp1 lorsque le facteur est retiré (ordre indicatif, un seul découpage).

Ce constat suggère, à titre indicatif, que dans un contexte de données d'apprentissage limitées, le type d'information fourni au réseau (la complétude multimodale) pèse davantage sur la précision globale que les raffinements algorithmiques appliqués à ces informations. Le classement H1 > H2 > H4 reste un résultat indicatif : il repose sur seulement 35 séquences de test et sur une seule initialisation aléatoire par configuration.

5.7.2 Fusion multimodale : contribution et comparaison des stratégies

L'analyse de la transition d'une approche naïve à une approche maîtrisée met en lumière les défis de l'intégration multimodale : **L'échec de l'Early Fusion brute :** La tentative initiale d'Early Fusion par simple concaténation des repères (*landmarks*) a provoqué un échec quasi total de l'apprentissage (Accuracy ≈20 %, proche du niveau de hasard de 14,3 % pour 7 classes). Cet échec ne remet pas en cause la fusion en elle-même, mais s'explique par un déséquilibre dimensionnel massif : les repères faciaux représentent à eux seuls 1404 des 1662 descripteurs d'entrée (soit 84.5%), ce qui a complètement submergé le signal discriminant des mains.

La correction par projection intermédiaire : L'introduction d'une projection linéaire ramenant chaque modalité à une dimension commune (d=32) avant concaténation a permis à l'Early Fusion de remonter à 77.1% d'accuracy.

L'avantage observé de la Late Fusion : Malgré cette correction, la fusion tardive (*Late Fusion*, Exp1) conserve un avantage de 20,0 points d'accuracy (97,1 % contre 77,1 %). En traitant chaque canal dans une branche récurrente indépendante avant la décision, la Late Fusion préserve plus longtemps l'identité et la dynamique temporelle propres à chaque modalité.

5.7.3 Contribution du mécanisme d'Attention

L'intégration de la couche d'attention spatio-temporelle après le bloc BiLSTM apporte une double contribution : **Gain en performance (+14.2 points) :** L'ablation de l'attention (Exp4, 82.9%) montre que sans ce mécanisme, le modèle peine à distinguer les séquences présentant des configurations manuelles très proches (HowOldAreYou vs ThankYou).

Explicabilité et interprétabilité temporelle (H4) : L'analyse des poids d'attention extraits révèle que le modèle n'accorde pas la même importance à toutes les frames de la vidéo. Il attribue des coefficients significativement élevés (atteignant 0.85) aux phases clés de la tenue du signe (*stroke*) et aux apex des expressions faciales, tout en ignorant les mouvements de transition neutres en début et fin d'exécution.

5.7.4 Contribution des différentes modalités

L'effondrement des performances lors de l'ablation des modalités non-manuelles dans l'Exp3 (chute à 54.3%) illustre le rôle grammatical fondamental du visage et de la posture.

Dans notre corpus de 7 signes U-ArSL, 4 classes correspondent à des phrases interrogatives conversationnelles (HowAreYou, HowOldAreYou, WhatDoYouWant, What'sYourName). En Langue des Signes, l'intonation interrogative est principalement véhiculée par des composantes non-manuelles : le froncement des sourcils, le squint des yeux, le mouvement de la bouche et l'inclinaison du buste. Ces descripteurs sont portés par la branche Visage du modèle (1404 variables) et la branche Posture.

La dépendance du modèle envers ces canaux non-manuels n'est donc pas un biais artificiel du réseau, mais reflète fidèlement la réalité linguistique et la structure grammaticale de la langue des signes.

5.7.5 Apport de la couche sémantique et de l'ontologie

Le couplage entre l'architecture profonde et l'ontologie phonologique OWL (conçue au Chapitre 3) franchit une étape clé en passant d'un simple classifieur "boîte noire" à un système d'analyse neuro-symbolique explicable.

L'apport de cette couche sémantique se manifeste sur trois niveaux majeurs : **Diagnostic phonologique et audit des erreurs :** Lorsqu'une erreur de classification survient (telle que l'unique mauvaise prédiction de l'Exp1 associant HowOldAreYou à PeaceBeUponYou), le réseau de neurones seul n'offre qu'un vecteur de probabilités Softmax sans explication causale. La requête SPARQL appliquée à l'ontologie permet d'isoler immédiatement l'intersection de leurs descripteurs phonologiques : les deux signes sont des signes composés (`isCompound` = true), exécutés principalement avec une seule main (`isTwoHanded` = false), avec une zone d'articulation initiale proche (`hasLocation`). L'ontologie explicite ainsi la proximité de ces deux concepts dans l'espace latent.

Levée des ambiguïtés visuelles (perspective) : Dans les cas où le signal vidéo est dégradé ou partiel, des règles d'inférence (par exemple SWRL) et des contraintes de domaine pourraient, dans une version future, permettre de filtrer les prédictions numériquement probables mais linguistiquement impossibles (par exemple, valider qu'un signe d'interrogation requiert formellement un trait non-manuel interrogatif).

Interprétabilité dirigée par le domaine : Plutôt que de s'appuyer uniquement sur des méthodes post-hoc génériques (telles que LIME ou SHAP), l'ontologie fournit une grille de lecture directement alignée sur les concepts de la linguistique de la langue des signes (configurations de la main, orientations, emplacements et composants non-manuels).

5.7.6 Analyse du comportement d'apprentissage

L'analyse de la dynamique d'entraînement constitue un indicateur central de la stabilité d'une architecture neuronale, en particulier lorsque le corpus d'apprentissage est de taille modérée (286 séquences).

Résolution du surapprentissage (Overfitting)

Le modèle de référence initial (Phase 1), caractérisé par une architecture *single-stream* à forte capacité (**934 000 paramètres**), présentait une divergence marquée entre la perte d'entraînement et la perte de validation dès les premières époques — symptôme classique d'une mémorisation du bruit du jeu de données.

Le modèle retenu en Phase 2 (**Exp1**, 149 000 paramètres) ne présente plus ce problème, grâce à la combinaison de deux leviers (dont les effets respectifs n'ont pas été isolés) :

Une régularisation renforcée au niveau applicatif : L'application de taux de Dropout élevés (0.4–0.5) entre les couches récurrentes, l'injection d'une pénalité L2 sur les poids de la couche de décision, et le déclenchement d'un arrêt précoce (*EarlyStopping*) basé sur la perte de validation.

Une réduction structurelle du nombre de paramètres : En appliquant une projection linéaire intermédiaire réduisant les 1662 descripteurs d'entrée vers des espaces de faible dimension (d=32 à 48) avant l'injection dans les blocs BiLSTM, la dimensionnalité d'entrée de la couche récurrente est divisée par plus de 40. Cette compression architecturale neutralise la

sur-paramétrisation tout en préservant la dynamicité spatio-temporelle.

Stabilité et convergence des courbes

Les courbes de perte (*loss*) d'entraînement et de validation de l'Exp1 montrent une décroissance fluide et parallèle sur les 100 époques. La perte de test se stabilise à **0.275** sans remontée tardive, confirmant que le modèle a appris des représentations généralisables plutôt qu'un simple apprentissage par cœur.

5.7.7 Discussion des résultats par rapport aux travaux existants

Le Tableau 5.6 situe l'architecture proposée (**Exp1**) par rapport à quelques travaux de la littérature sur la langue des signes. Les résultats sont ceux rapportés par leurs auteurs, sur des jeux de données, des classes et des protocoles différents : ils ne sont donc **pas directement comparables** aux nôtres, et ces architectures n'ont pas été réimplémentées sur notre corpus.

Tab. 5.6 : Positionnement par rapport à quelques travaux de la littérature (résultats rapportés par les auteurs, non directement comparables)

Travaux	Modalités	Architecture	Ontologie	Résultat rapporté
Elsayed & Fathy [8]	Mains (images statiques)	CNN	Oui (WordNet, lexicale)	88,87 % (ArSL2018) ; 94,31 % de précision sémantique
Algethami et al. [6]	MediaPipe (258 points par frame)	TCN et BiLSTM	Non	99,5 % (ArSL continu)
Alsharif et al. [5]	YOLOv11 et MediaPipe (ASL)	Détection en temps réel	Non	98,2 % (mAP)
Notre approche (Phase 1)	Holistic, flux unique	BiLSTM (934K paramètres), 9 classes	Non	91,3 %
Notre approche (Exp1, Phase 2)	Holistic, quatre branches	BiLSTM + attention, Late Fusion (149K paramètres)	Oui (OWL, après la classification)	97,1 % (7 classes, 35 séquences de test, intra-signeur)

Notre accuracy de 97,1 % est obtenue sur 7 classes conversationnelles, 35 séquences de test et un découpage intra-signeur. Elle ne doit pas être mise sur le même plan que les résultats cités, notamment ceux évalués sur de plus grands jeux de données ou en mode inter-signeurs. Deux éléments distinguent néanmoins notre approche : une architecture compacte (148 907 paramètres), dont l'adéquation à des équipements à ressources limitées reste à valider, et, à notre connaissance, un couplage encore peu exploré dans la littérature ArSL entre un reconnaisseur

vidéo et une ontologie phonologique (l'approche lexicale de [8] en est la référence la plus proche).

5.8 Limites, biais et éthique

Bien que les performances obtenues soient encourageantes, une démarche de recherche prudente impose d'expliciter en toute transparence les contraintes et limites méthodologiques qui encadrent ces résultats.

5.8.1 Taille et diversité du corpus

Le corpus d'évaluation reste restreint, comptant **7 classes gestuelles** et un total de **356 séquences** (286 en entraînement, 35 en validation et 35 en test). Si ces résultats sont encourageants pour la méthodologie proposée, ils ne sauraient garantir une généralisation directe à un dictionnaire de plusieurs centaines ou milliers de signes sans adaptation de la capacité du réseau.

5.8.2 Troncature et padding des séquences

Le choix d'un seuil maximal fixe de frames (Tmax =150) pour l'harmonisation des séquences d'entrée introduit un biais méthodologique : Les vidéos plus courtes subissent un *padding* par zéros qui peut diluer l'information temporelle.

Les vidéos particulièrement longues (>150 frames) subissent une troncature automatique. Cette troncature a pu contribuer à l'unique erreur de classification du jeu de test (HowOldAreYou), en supprimant la phase d'exécution finale du signe ; ce lien n'a pas été vérifié expérimentalement.

5.8.3 Validation limitée (signeurs et variabilité des seeds)

En raison de la taille du corpus disponible pour l'U-ArSL, le jeu de test a été constitué par découpage stratifié aléatoire. Contrairement à certaines expérimentations de la Phase 1, une évaluation stricte de type *Leave-One-Signer-Out* (LOSO) n'a pas pu être menée sur le modèle retenu. De plus, la sensibilité aux graines d'initialisation aléatoire (*random seeds*) sur un jeu de test de 35 séquences implique que chaque erreur individuelle pèse environ 2.86 points d'accuracy.

5.8.4 Degré de couplage entre modèle neuronal et ontologie

Actuellement, l'intégration entre le réseau de neurones et l'ontologie OWL fonctionne selon une logique **loose-coupling (couplage lâche)** ou *post-hoc* : le réseau prédit les classes et les poids d'attention, puis l'ontologie est interrogée pour valider ou expliquer le résultat. Un couplage serré

(*tight-coupling*), où les règles sémantiques contraignent directement la fonction de perte (*loss*) pendant la rétropropagation, constitue une limite à franchir pour les travaux futurs.

5.9 Conclusion du chapitre

En somme, l'analyse approfondie des résultats confirme l'efficacité de l'architecture neuro-symbolique proposée. La hiérarchisation claire des choix de conception — plaçant la complétude multimodale (H1) et la stratégie de fusion tardive (H2) au-dessus des affinements d'attention (H4) — fournit une directive méthodologique précieuse pour la communauté scientifique en reconnaissance de la langue des signes.

Malgré les contraintes liées à la taille du corpus et au mode de couplage de l'ontologie, le modèle parvient à concilier une précision de 97,1 % sur le jeu de test, un nombre réduit de paramètres (148 907) et un enrichissement phonologique permettant d'appuyer l'interprétation des prédictions.

Les chapitres précédents ayant présenté la conception, la validation expérimentale et la discussion critique de notre système, ce dernier chapitre synthétise les contributions majeures de ce mémoire et esquisse les perspectives de recherche prioritaires pour l'extension de ce travail.

Conclusion générale et perspectives

Bilan. Ce mémoire s'est consacré à la conception et à l'évaluation d'une architecture hybride, associant un réseau neuronal multimodal et une ontologie OWL phonologique, pour la reconnaissance de la Langue des Signes Arabe Unifiée (U-ArSL) et la description sémantique des signes reconnus. Le système reconnaît d'abord un signe, puis lui associe une description issue de l'ontologie. Les résultats, obtenus sur un corpus restreint et en évaluation intra-signeur, sont présentés comme une preuve de concept.

Apports. Ce travail apporte quatre contributions :

1. **Un corpus U-ArSL mauritanien** de 356 séquences, enregistrées auprès de dix enfants sourds et validées par un enseignant sourd, expert de l'U-ArSL.
2. **Une ontologie OWL phonologique couplée au reconnaisseur**, interrogée après la classification pour décrire le signe prédit et appuyer l'analyse des erreurs, sans coût sur l'inférence neuronale.
3. **Un modèle multimodal compact** (quatre branches, BiLSTM, attention, Late Fusion, 149K paramètres) atteignant 97,1 % d'accuracy sur 7 classes, et un prototype de bout en bout (`predict.py`).
4. **Une étude d'ablation exploratoire**, dont les résultats suggèrent que le choix des modalités d'entrée (H1) pèse davantage que la stratégie de fusion (H2), qui pèse elle-même davantage que l'attention (H4). Ce classement est indicatif : il repose sur 35 séquences de test et une seule initialisation aléatoire par configuration.

Limites. Les principales limites, discutées à la section 5.8, concernent la taille et la diversité du corpus, la troncature et le padding des séquences, la validation limitée (signeurs et initialisations) et le degré de couplage entre le modèle neuronal et l'ontologie.

Perspectives. Sur la base des limites méthodologiques identifiées à la section 5.8, les travaux futurs s'orientent selon trois axes prioritaires :

Extension du corpus et du vocabulaire

Élargissement du dictionnaire : Étendre le vocabulaire à 50 signes ou plus afin d'évaluer la scalabilité de la représentation vectorielle et la capacité de généralisation de la fusion tardive sur un espace de classes plus dense.

Traitement du contexte continu : Évoluer de la reconnaissance de signes isolés vers la gestion de la langue des signes continue, en intégrant la modélisation des phénomènes de coarticulation entre les gestes.

Optimisation du prétraitement et validation

Ré-échantillonnage temporel adapté (*Resampling*) : Remplacer la troncature fixe à Tmax =150 frames par un sous-échantillonnage temporel uniforme sur l'intégralité de la séquence. Cette stratégie pourrait préserver la totalité du mouvement (notamment la phase d'exécution finale des signes longs comme HowOldAreYou) et traiter ainsi une cause possible de l'unique erreur de classification observée.

Protocoles de validation avancés : Mener des tests de validation inter-signeurs systématiques (*Leave-One-Signer-Out*) sur l'architecture révisée pour garantir une robustesse optimale face à la variabilité morphologique des utilisateurs.

Intégration neuro-symbolique et déploiement

Couplage sémantique au niveau de l'apprentissage : Évoluer du couplage lâche actuels vers un apprentissage multi-tâches ou guidé par la connaissance, où les propriétés phonologiques issues de l'ontologie agissent comme des signaux d'apprentissage auxiliaires pour pénaliser les erreurs au cours de la rétropropagation.

Déploiement sur dispositifs mobiles (Edge AI) : Exploiter la légèreté de l'architecture (149K paramètres) pour concevoir une application embarquée sur smartphone, dans une perspective directe d'accessibilité numérique pour la communauté sourde.

Mot de conclusion. Ce travail suggère qu'il est possible, même avec un corpus de taille modeste, de construire un système de reconnaissance de langue des signes compact et dont les prédictions peuvent être commentées, à condition de concevoir l'architecture neuronale avec soin et de la coupler à une représentation symbolique structurée du domaine. Au-delà des métriques chiffrées, la contribution essentielle de ce mémoire réside dans l'indication qu'un système de reconnaissance peut dépasser la simple prédiction d'étiquettes textuelles pour produire une description phonologique et sémantique associée au signe reconnu.

Bilan personnel. Ce projet a représenté pour moi bien plus qu'un simple travail de recherche. Au début, je ne connaissais pas la langue des signes. Mais lorsque l'idée de travailler sur sa reconnaissance a commencé à prendre forme, je me suis posé une question essentielle : comment pourrais-je construire une technologie destinée à une communauté que je ne connais pas réellement ?

Je ne voulais pas simplement travailler sur des vidéos, des données ou des modèles d'intelligence artificielle sans comprendre ce qu'ils représentaient. J'ai donc décidé de chercher un endroit où apprendre la langue des signes. J'ai commencé cet apprentissage parallèlement à mon projet, avec la volonté de comprendre réellement ce que j'étais en train de construire.

Cette expérience m'a permis d'entrer progressivement dans un univers que je ne connaissais pas, de communiquer avec des personnes sourdes et de mieux comprendre leurs besoins, leurs difficultés et leur manière de communiquer. Plus j'apprenais, plus je réalisais que derrière chaque

geste reconnu par un modèle, il y avait une langue, une culture, une personne et une manière particulière de s'exprimer.

Cette démarche a également changé ma manière de voir mon propre projet. Mon objectif n'était plus seulement d'obtenir de bonnes performances avec un modèle d'intelligence artificielle, mais de contribuer, à mon échelle, à réduire les barrières de communication et à rendre la technologie plus accessible.

Ce projet m'a ainsi permis d'acquérir des compétences techniques, scientifiques et humaines. Sur le plan technique, j'ai appris à extraire les points clés avec MediaPipe, à concevoir et évaluer des réseaux BiLSTM avec mécanisme d'attention, à réaliser des expériences d'ablation et à modéliser les connaissances à l'aide d'une ontologie OWL.

Sur le plan scientifique, j'ai appris à rédiger un article scientifique et à répondre aux remarques des évaluateurs. Sur le plan humain, le travail avec des enfants sourds et avec un enseignant expérimenté m'a particulièrement sensibilisée à l'importance de l'accessibilité technologique et aux responsabilités éthiques de la recherche, notamment le respect des participants et le consentement des familles.

Au final, ce projet m'a appris une chose essentielle : pour construire une technologie destinée à l'humain, il faut d'abord chercher à comprendre l'humain. C'est probablement l'un des enseignements les plus importants que je retiendrai de ce travail, et il renforce ma volonté de poursuivre dans le domaine de l'intelligence artificielle inclusive.

Bibliographie

[1] F. Schroff, D. Kalenichenko, and J. Philbin, "FaceNet : A unified embedding for face recognition and clustering," in *Proceedings of CVPR 2015*, pp. 815–823, 2015.

[2] A. Hermans, L. Beyer, and B. Leibe, "In defense of the triplet loss for person re-identification," *arXiv preprint arXiv :1703.07737*, 2017.

[3] D. Bragg *et al.*, "Sign language recognition, generation, and translation : An interdisciplinary perspective," in *Proceedings of ASSETS 2021*, pp. 331–343, 2021.

[4] Y. Obi, K. S. Claudio, V. M. Budiman, S. Achmad, and A. Kurniawan, "Sign language recognition system for communicating to people with disabilities," *Procedia Computer Science*, vol. 216, pp. 13–20, 2023.

[5] B. Alsharif, E. Alalwany, A. Ibrahim, I. Mahgoub, and M. Ilyas, "Real-Time American Sign Language Interpretation Using Deep Learning and Keypoint Tracking," *Sensors*, vol. 25, no. 7, p. 2138, 2025.

[6] N. Algethami, R. Farhud, M. Alghamdi, H. Almutairi, M. Sorani, and N. Aleisa, "Continuous Arabic Sign Language Recognition Models," *Sensors*, vol. 25, no. 9, p. 2916, 2025.

[7] M. Ibrahim, M. Ghantous, and N. Sharaf, "Dataset Generation for Egyptian Arabic Sign Language," in *Proceedings of ICAART 2025*, pp. 1419–1426, 2025.

[8] E. K. Elsayed and D. R. Fathy, "Sign Language Semantic Translation System using Ontology and Deep Learning," *International Journal of Advanced Computer Science and Applications (IJACSA)*, vol. 11, no. 1, pp. 141–147, 2020.

[9] M. Abdel-Fattah, "Arabic sign language : a perspective," *Journal of Deaf Studies and Deaf Education*, vol. 10, no. 2, pp. 212–221, 2005. doi :10.1093/deafed/eni007.

[10] M. Jebali, P. Dalle, and M. Jemni, "Extension of hidden Markov model for recognizing large vocabulary of sign language," *arXiv preprint arXiv :1304.3265*, 2013.

[11] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[12] A. Graves and J. Schmidhuber, "Framewise phoneme classification with bidirectional LSTM and other neural network architectures," *Neural Networks*, vol. 18, no. 5–6, pp. 602–610, 2005.

[13] B. Alabduallah, R. Al Dayil, A. Alkharashi, and A. A. Alneil, "Innovative hand pose based sign language recognition using hybrid metaheuristic optimization algorithms with deep learning model," *Scientific Reports*, vol. 15, p. 9320, 2025.

[14] J. Immanuel and S. Berrezueta-Guzman, "Accessible American Sign Language Learning in Virtual Reality via Inverse Kinematics," *Virtual Worlds*, vol. 4, no. 4, p. 57, 2025.

[15] D. Bahdanau, K. Cho, and Y. Bengio, "Neural Machine Translation by Jointly Learning to Align and Translate," in *Proceedings of ICLR 2015*, 2015.

[16] T. Baltrusaitis, C. Ahuja, and L.-P. Morency, "Multimodal Machine Learning : A Survey and Taxonomy," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2019.

[17] C. Lugaresi *et al.*, "MediaPipe : A Framework for Building Perception Pipelines," *arXiv preprint arXiv :1906.08172*, 2019.

[18] C. Neidle, J. Kegl, D. MacLaughlin, B. Bahan, and R. G. Lee, *The Syntax of American Sign Language : Functional Categories and Hierarchical Structure*. MIT Press, 2000.

[19] T. Declerck *et al.*, "Towards a New Ontology for Sign Languages," in *Proceedings of LREC 2022*, pp. 3977–3983, 2022.

[20] T. Declerck, "Towards the Linking of a Sign Language Ontology with Lexical Data," in *Globalex Workshop on Linked Lexicography, LREC 2022*, pp. 6–9, 2022.

[21] A. M. Sevinç, "An event-based ontology for sign language phonology," in *Proceedings of the ESSLLI 2015 Student Session*, pp. 213–224, 2015.

[22] W. Sandler and D. Lillo-Martin, *Sign Language and Linguistic Universals*. Cambridge University Press, 2006.

[23] Z. Yang, D. Yang, C. Dyer, X. He, A. Smola, and E. Hovy, "Hierarchical Attention Networks for Document Classification," in *Proceedings of NAACL-HLT 2016*, pp. 1480–1489, 2016.

[24] W. C. Stokoe, *Sign Language Structure : An Outline of the Visual Communication Systems of the American Deaf*. Studies in Linguistics : Occasional Papers 8, University of Buffalo, 1960. Réimprimé dans *Journal of Deaf Studies and Deaf Education*, 10(1), 3–37, 2005.

Annexe A

Extraits de code commentés et lien vers le dépôt

Le code source et l'ontologie (`sign_language_ontology.owl`) sont disponibles à l'adresse suivante : `https://github.com/MekfouleElbechir/SignLanguageProject`.

Les scripts principaux sont les suivants :

- `inventory_npy_and_split.py` : inventaire des séquences et découpage des données (fonction `split_dataset`) ;
- `preprocessing.py` : séparation des modalités, padding et troncature ;
- `model.py` : architectures BiLSTM + Attention ;
- `train.py` : entraînement et évaluation ;
- `predict.py` : prédiction et interrogation de l'ontologie ;
- `app.py` : interface de démonstration (Streamlit).

Extrait simplifié du mécanisme d'interrogation de l'ontologie (`predict.py`) :

```
import rdflib
from rdflib.namespace import RDFS

g = rdflib.Graph()
g.parse("sign_language_ontology.owl", format="xml")

# Recherche de l'individu Sign_X correspondant au label predit
for s, p, o in g.triples((None, RDFS.label, None)):
    if normalize(str(o)) == normalize("Sign_" + predicted_label):
        target_uri = s

# Extraction des proprietes phonologiques (triple matching, sans
   inference)
for p, o in g.predicate_objects(subject=target_uri):
    ...
```

Annexe B

Détails du jeu de données

Les caractéristiques du corpus (356 séquences, 7 classes, 1 662 features par frame), la distribution des séquences par classe et la répartition stratifiée entraînement/validation/test sont présentées aux sections 3.2 et 4 (Tableaux 3.1, 3.2 et 4.1). La description phonologique des sept signes est donnée au Tableau 3.8. Cette annexe complète ces éléments par le protocole d'enregistrement et le modèle de formulaire de consentement.

B.1 Protocole d'enregistrement

Les enregistrements, réalisés en 2025 avant le stage, se sont déroulés selon les étapes suivantes. Les caractéristiques techniques détaillées figurent au Tableau 3.1.

1. **Cadre.** Les enregistrements ont eu lieu au sein d'un établissement spécialisé accueillant des enfants sourds, où l'U-ArSL est la langue d'enseignement.
2. **Participants et autorisation.** Dix enfants sourds, âgés de 8 à 14 ans, ont participé, chacun avec l'autorisation écrite de ses tuteurs légaux (modèle présenté à la section suivante).
3. **Choix des expressions.** Les sept expressions conversationnelles ont été sélectionnées avec un enseignant sourd, expert de l'U-ArSL, afin qu'elles correspondent à l'usage réel de la langue enseignée.
4. **Dispositif.** Une caméra Canon fixe (1920×1080, 29,97 fps) était placée à environ 1,5–1,6 m de l'enfant, en lumière naturelle. L'enfant se tenait debout, de face, devant un mur uni de teinte claire, sans objet visible, et était cadré de la tête jusqu'aux hanches environ, les bras le long du corps au repos (Figure B.1).
5. **Déroulement.** Neuf sessions d'enregistrement ont été organisées, chacune sous la supervision de l'enseignant sourd. Pour chaque signe, l'enseignant montrait d'abord le signe correct, puis l'enfant le reproduisait face à la caméra ; chaque enfant a exécuté environ cinq répétitions de chaque signe.
6. **Vérification.** Chaque séquence a été vérifiée par l'enseignant sourd ; les séquences incomplètes ou mal exécutées ont été écartées.
7. **Traitement et conservation.** Les landmarks ont été extraits avec MediaPipe Holistic et enregistrés au format `.npy` ; les vidéos brutes sont conservées de manière privée et ne sont pas diffusées.

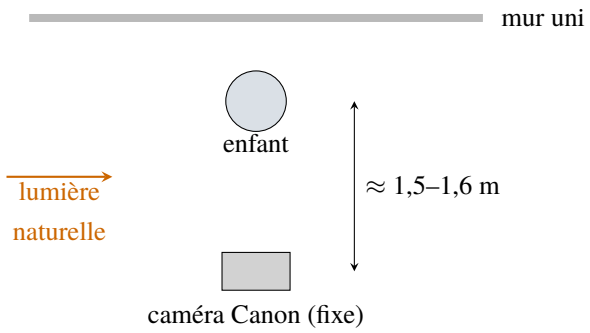


Fig. B.1 : Schéma du dispositif d'enregistrement (vue de dessus, non à l'échelle).

B.2 Modèle de formulaire de consentement

Les tuteurs légaux de chaque enfant ont signé un formulaire d'autorisation rédigé en arabe. Son modèle vierge est reproduit à la Figure B.2. Aucun formulaire signé n'est joint, afin de protéger l'identité des participants ; le numéro de téléphone de contact a été masqué. Le contenu du formulaire est résumé ci-dessous en français.

Titre. Consentement du parent ou tuteur légal à la participation du volontaire au développement d'une application éducative et de traduction de la langue des signes.

Informations demandées. Date ; nom complet du parent, numéro d'identité (s'il existe), lien de parenté avec le volontaire et numéro de téléphone ; nom, date de naissance et âge du volontaire ; nom, signature et date du parent ou tuteur.

Objet de l'autorisation. Le parent ou tuteur légal autorise la participation de l'enfant à un projet de développement d'une application d'apprentissage ou de traduction de la langue des signes, qui comprend :

- l'enregistrement de courtes vidéos dans lesquelles l'enfant réalise des signes ;
- l'utilisation de ces vidéos dans un projet susceptible d'évoluer ultérieurement (application, entreprise émergente ou service numérique) ;
- l'utilisation des données et des vidéos pour l'entraînement de modèles d'intelligence artificielle et le développement de logiciels.

Engagements de l'équipe.

1. Ne pas publier ni diffuser publiquement les vidéos sur une plateforme sans nouvelle autorisation.
2. Conserver l'ensemble des données et des vidéos de façon strictement confidentielle, sans les partager avec un tiers extérieur au projet.

3. Le formulaire précise que le parent ne peut pas retirer son consentement une fois les données de l'enfant intégrées à la base (clause jugée trop restrictive : voir la section 1.3 et la proposition de révision).

Usage prévu des données. Le formulaire autorise l'usage des données pour la recherche et le développement de logiciels, y compris dans un projet susceptible d'évoluer en application, entreprise émergente ou service numérique. Le présent mémoire n'utilise ces données qu'à des fins de recherche scientifique (section 1.3).

Présentation de l'équipe et du projet. Le formulaire présente deux étudiants du Master Machine Learning & Data Science (MLDS) de la Faculté des Sciences et Techniques de l'Université de Nouakchott. Le projet s'inscrit dans une recherche de fin d'études et vise à développer un prototype d'application d'aide à la traduction de la langue des signes vers du texte ou de la parole, à l'aide de l'intelligence artificielle.



موريتانيا ، نواكشوط كلية العلوم و التقنيات شرف إخاء عدالة

موافقة ولي الأمر على مساهمة المتطوع في تطوير تطبيق تعليمي/ ترجمي للغة الإشارة

- التاريخ: [.....]
- أنا الموقع أدناه:
- الاسم الكامل لولي الأمر: .....
- رقم الهوية (إن وجد): .....
- صلة القرابة بالمتطوع: .....
- رقم الهاتف: .....
- أُقر بأنني ولي أمر/الوصي القانوني للمتطوع:
- اسم المتطوع: .....
- تاريخ الميلاد: ..... / ..... / .....
- العمر: .....
- التوقيع:
- الاسم الكامل: .....
- التوقيع: .....
- التاريخ: ...../...../.....

وأوافق على مشاركة ابني/ابنتي في مشروع تطوير تطبيق لتعليم أو ترجمة لغة الإشارة، والذي يشمل:

- تسجيل فيديوهات قصيرة يؤدي فيها إشارات بلغة الإشارة.
- استخدام هذه الفيديوهات ضمن مشروع قد يتطور لاحقًا إلى (تطبيق ، شركة ناشئة أو خدمة رقمية).
- استخدام البيانات والفيديوهات لأغراض تدريب نماذج الذكاء الاصطناعي وتطوير البرمجيات.

مع الالتزام التام بالآتي:

1. عدم نشر الفيديوهات أو عرضها علنًا على أي منصة بدون موافقة جديدة لاحقًا.
2. حفظ جميع البيانات والفيديوهات بسرية تامة، وعدم مشاركتها مع أي طرف خارجي غير معني بالمشروع.
3. لا يمكنني (كولي أمر) سحب هذه الموافقة بعد ادراجها في البيانات .

تعريف الفريق والمشروع

نحن:

مكفولة سيد المختار البشير ،أسامة محمد عالي دداه طالبان في كلية العلوم والتقنيات - جامعة نواكشوط، تابع دراستنا في تخصص الذكاء الاصطناعي – فرع تعلم الآلة وتحليل البيانات (MLDS).

هذا المشروع جزء من بحث تخرج نعمل عليه، ويهدف لتطوير نموذج أولي لتطبيق يساعد على ترجمة لغة الإشارة إلى نصوص أو كلام، باستخدام الذكاء الاصطناعي.

للتواصل و الإستفسار

رقم الهاتف:

مع خالص التقدير،فريق العمل

Fig. B.2 : Modèle vierge du formulaire de consentement parental (en arabe).

B.3 Autorisation de l’établissement

Avant la collecte, le directeur général de l’établissement spécialisé a délivré une autorisation écrite, datée du 27/05/2025 (Figure B.3). Le numéro de téléphone de contact de l’équipe a été masqué. Son contenu est résumé ci-dessous en français.

Objet. Autorisation de la contribution de volontaires au développement d’une application éducative et de traduction de la langue des signes, délivrée au nom du Ministère de l’Action sociale, de l’Enfance et de la Famille.

Bénéficiaires. L'équipe de travail, composée des deux étudiants de la Faculté des Sciences et Techniques cités dans le formulaire parental, en qualité de développeurs d'application et chercheurs.

Contenu de l'autorisation. Droit de collecter les données relatives à la langue des signes auprès de personnes sourdes accueillies par l'établissement, pour le développement d'une application de traduction de la langue des signes. Ces données comprennent : des enregistrements vidéo de mouvements de signes, des traductions textuelles équivalentes et des observations ou commentaires des participants.

Conditions. La collecte s'effectue dans le respect de l'éthique professionnelle et de la vie privée des participants. Les informations ne sont pas utilisées à des fins commerciales ou personnelles sans autorisation écrite préalable.

Durée. L'autorisation court de la date de signature jusqu'à la fin du projet, ou jusqu'à son retrait écrit par l'établissement.



الجمهورية الإسلامية الموريتانية
شرف - إخاء - عدل

RÉPUBLIQUE ISLAMIQUE DE MAURITANIE
Honneur - Fraternité - Justice

وزارة العمل الاجتماعي والطفولة والاسرة
Ministère de l'Action sociale, de l'Enfance et de la famille
مركز التكوين و الترقية الاجتماعية للأطفال ذوي الإعاقة
CENTRE DE FORMATION ET DE PROMOTION SOCIALE DES ENFANTS ET EN SITUATION DE HANDICAP
المدير
Le Directeur

Nouakchott, le _____ نواكشوط في
Numéro _____ الرقم

موافقة المدير على مساهمة المتطوعين في تطوير تطبيق تعليمي/ ترجمي للغة الإشارة

التاريخ: [27/05/2025]
اسم المؤسسة أو الجهة : وزارة العمل الاجتماعي و الطفولة و الأسرة (مركز التكوين و الترقية الاجتماعية)

أنا الموقع أدناه:
الصفة/المنصب: المدير العام
بصفتي: [مدير المركز]
أُقر بموافقتي على منح:
فريق العمل : مكفولة سيد المختار البشير و أسامة محمد عالي الدداه
الصفة: [مطورين تطبيق / باحثين]
الحق الكامل والصريح في جمع البيانات المتعلقة بلغة الإشارة من الأفراد الصم الذين يتعاملون مع مؤسستنا، وذلك لأغراض تطوير تطبيق لترجمة لغة الإشارة.
وتشمل هذه البيانات، على سبيل المثال لا الحصر:

- تسجيلات مرئية لحركات الإشارات
- ترجمات نصية مكافئة
- ملاحظات أو تعليقات من المشاركين

ويتم جمع هذه البيانات مع الالتزام الكامل بالأخلاقيات المهنية، والحفاظ على خصوصية المشاركين، وعدم استخدام المعلومات لأغراض تجارية أو شخصية دون إذن خطي مسبق.
تُمنح هذه الموافقة لفترة تبدأ من تاريخ توقيع هذه الوثيقة، وتستمر حتى الانتهاء من المشروع أو سحب الموافقة كتابياً من قبل المؤسسة.

تعريف الفريق والمشروع
نحن:
مكفولة سيد المختار البشير ،أسامة محمد عالي الدداه طالبان في كلية العلوم والتقنيات - جامعة نواكشوط،
تابع دراستنا في تخصص الذكاء الاصطناعي - فرع تعلم الآلة وتحليل البيانات (MLDS).
هذا المشروع جزء من بحث تخرج نعمل عليه، ويهدف لتطوير نموذج أولي لتطبيق يساعد على ترجمة لغة الإشارة إلى نصوص أو كلام، باستخدام الذكاء الاصطناعي.
التواصل و الإستفسار
رقم الهاتف

مدير العام : سيدي سيد احمد الكناي
التوقيع :
الختم

مع خالص التقدير،فريق العمل

Fig. B.3 : Autorisation écrite du directeur général de l'établissement (27/05/2025).

Annexe C

Hyperparamètres et résultats complets

C.1 Model Card

Champ	Valeur
Modèle	ARSL_multimodal_bilstm_attention_latefusion (Exp1)
Tâche	Classification de 7 expressions segmentées de l'U-ArSL
Entrée	Séquences de landmarks MediaPipe Holistic (150 frames × 1 662 valeurs)
Architecture	4 branches (pose, main gauche, main droite, visage), BiLSTM + attention par branche, Late Fusion
Paramètres entraînables	148 907
Framework	TensorFlow 2.16.1 / Keras 3.15.0
Données	356 séquences d'enfants sourds (entraînement : 286 ; validation : 35 ; test : 35)
Accuracy (test)	0,971 (34/35) — IC à 95 % : [0,855 ; 0,995]
F1 macro (test)	0,971
Limites connues	Pas de validation inter-signeurs ; une seule initialisation ; troncature à 150 frames ; vocabulaire limité à 7 expressions
Usage prévu	Recherche et démonstration académique ; non destiné à un usage en production

C.2 Environnement technique

Le développement, l'entraînement et l'évaluation du système ont été réalisés avec les outils suivants (les versions exactes sont données ci-dessous) :

- **Langage de programmation :** Python ;
- **Apprentissage profond :** TensorFlow / Keras ;
- **Extraction des landmarks :** MediaPipe Holistic ;
- **Calcul scientifique et prétraitement :** NumPy, Pandas, Scikit-learn ;
- **Couche sémantique :** ontologie éditée avec Protégé, interrogée avec rdflib ;
- **Visualisation et métriques :** Matplotlib, Scikit-learn.

C.3 Configuration expérimentale

C.3.1 Environnement matériel

L'ensemble des expériences (extraction des landmarks, entraînement et évaluation) a été réalisé localement sur la machine suivante :

Composant	Valeur
Ordinateur	MacBook Air
Processeur	Apple M4 (CPU et GPU intégrés)
Mémoire RAM	16 Go
Système d'exploitation	macOS 26.3.1

C.3.2 Environnement logiciel

Bibliothèque	Version
Python	3.11.15
TensorFlow	2.16.1
Keras	3.15.0
MediaPipe	0.10.14
NumPy	1.26.4
Pandas	3.0.5
Scikit-learn	1.9.0
rdflib	7.6.0
Matplotlib	3.11.0
Protégé (édition de l'ontologie)	5.6.9

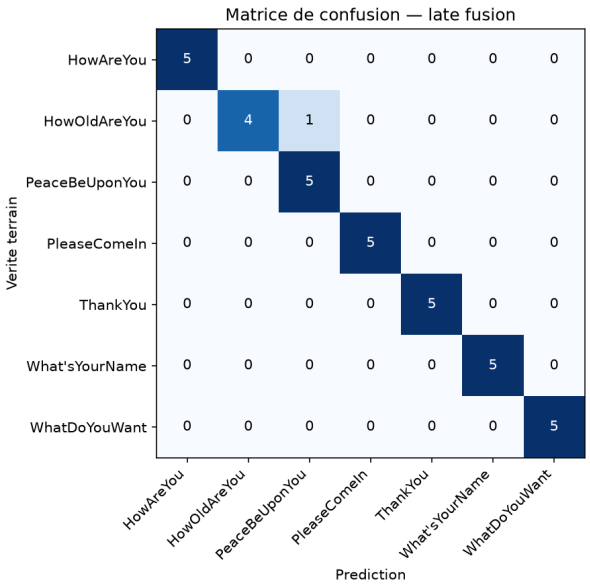
C.3.3 Organisation du projet et reproductibilité

Le projet est organisé en plusieurs répertoires :

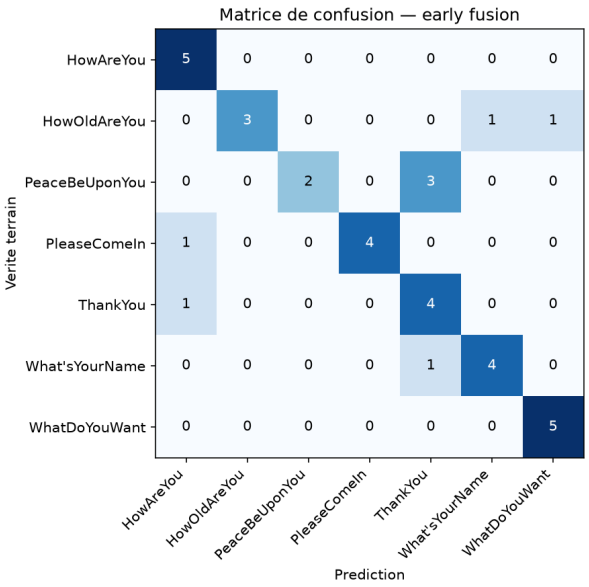
- `02_Donnees_organisee` : landmarks (.npy) organisés par classe ;
- `04_Experimentations_local` : un dossier par expérience (Exp1 à Exp4), contenant le modèle entraîné (.keras), le rapport de classification, la matrice de confusion et les courbes d'apprentissage ;
- `05_Code_Source` : scripts Python (Annexe A).

Le découpage des données est reproductible : il est réalisé par la fonction `split_dataset` (script `inventory_npy_and_split.py`), avec une graine fixée à 42 et 5 séquences par classe en validation et en test. En revanche, l'initialisation des poids du réseau n'est pas fixée explicitement : un nouvel entraînement peut donc produire des résultats légèrement différents. C'est pourquoi les modèles entraînés de chaque expérience ont été conservés, ce qui permet de réévaluer les résultats rapportés sans nouvel entraînement.

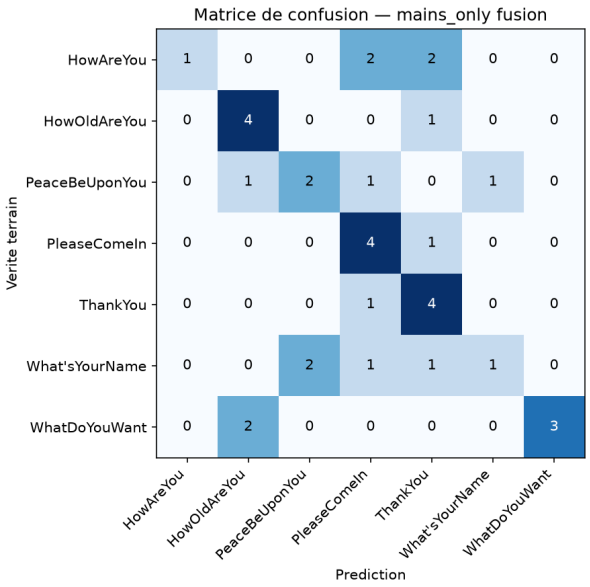
C.4 Matrices de confusion



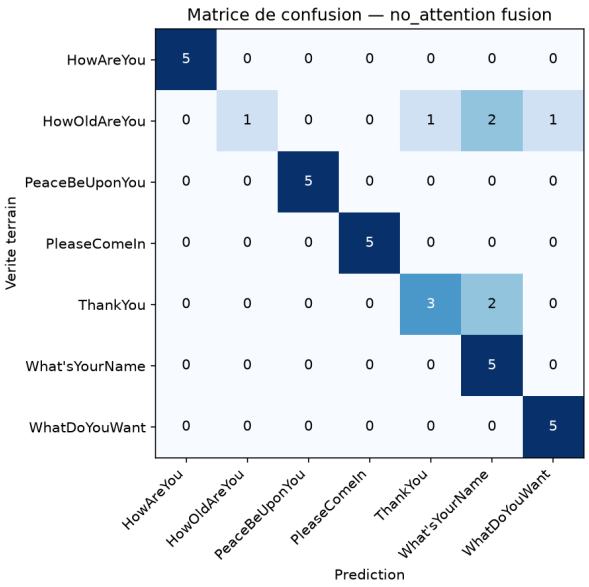
(a) Exp1 — Holistic + Late Fusion + Attention



(b) Exp2 — Early Fusion



(c) Exp3 — Mains seules



(d) Exp4 — Sans attention

Fig. C.1 : Matrices de confusion des quatre expériences sur le jeu de test (35 séquences).

C.5 Rapports de classification

Les rapports suivants donnent, pour chaque expérience, la précision, le rappel, le F1-score et le support de chaque classe sur le jeu de test (35 séquences).

Listing C.1 : Exp1 — Holistic + Late Fusion + Attention

```
Test accuracy : 0.971
Test loss : 0.275

                precision    recall  f1-score   support

     HowAreYou      1.000     1.000     1.000         5
  HowOldAreYou      1.000     0.800     0.889         5
PeaceBeUponYou      0.833     1.000     0.909         5
  PleaseComeIn      1.000     1.000     1.000         5
      ThankYou      1.000     1.000     1.000         5
What'sYourName      1.000     1.000     1.000         5
 WhatDoYouWant      1.000     1.000     1.000         5

      accuracy                          0.971        35
     macro avg      0.976     0.971     0.971        35
  weighted avg      0.976     0.971     0.971        35
```

Listing C.2 : Exp2 — Early Fusion

```
Test accuracy : 0.771
Test loss : 0.634

                precision    recall  f1-score   support

     HowAreYou      0.714     1.000     0.833         5
  HowOldAreYou      1.000     0.600     0.750         5
PeaceBeUponYou      1.000     0.400     0.571         5
  PleaseComeIn      1.000     0.800     0.889         5
      ThankYou      0.500     0.800     0.615         5
What'sYourName      0.800     0.800     0.800         5
 WhatDoYouWant      0.833     1.000     0.909         5

      accuracy                          0.771        35
     macro avg      0.835     0.771     0.767        35
  weighted avg      0.835     0.771     0.767        35
```

Listing C.3 : Exp3 — Mains seules

```
Test accuracy : 0.543
Test loss : 1.248

                precision    recall  f1-score   support

```

```
      HowAreYou       1.000     0.200     0.333          5
   HowOldAreYou       0.571     0.800     0.667          5
PeaceBeUponYou        0.500     0.400     0.444          5
   PleaseComeIn       0.444     0.800     0.571          5
       ThankYou       0.444     0.800     0.571          5
What'sYourName        0.500     0.200     0.286          5
 WhatDoYouWant        1.000     0.600     0.750          5

       accuracy                           0.543         35
      macro avg       0.637     0.543     0.518         35
   weighted avg       0.637     0.543     0.518         35
```

Listing C.4 : Exp4 — Sans attention

```
Test accuracy : 0.829
Test loss : 0.616

                precision    recall  f1-score   support

      HowAreYou       1.000     1.000     1.000          5
   HowOldAreYou       1.000     0.200     0.333          5
PeaceBeUponYou        1.000     1.000     1.000          5
   PleaseComeIn       1.000     1.000     1.000          5
       ThankYou       0.750     0.600     0.667          5
What'sYourName        0.556     1.000     0.714          5
 WhatDoYouWant        0.833     1.000     0.909          5

       accuracy                           0.829         35
      macro avg       0.877     0.829     0.803         35
   weighted avg       0.877     0.829     0.803         35
```

C.6 Courbes d'apprentissage

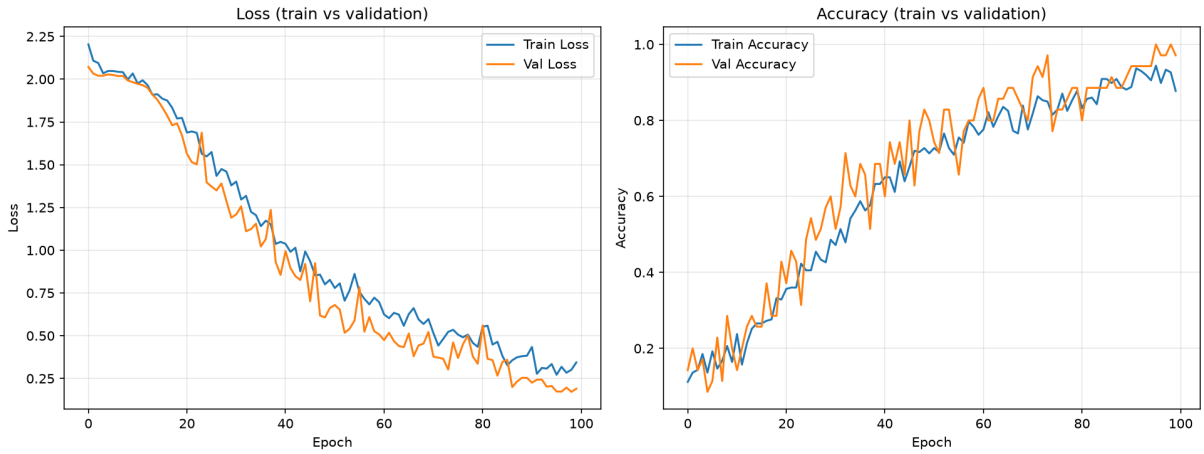


FIG. C.2 : Courbes de perte et d'accuracy (entraînement et validation) du modèle retenu (Exp1).

Annexe D

Maquettes, diagrammes et captures d'écran

D.1 Structure de l'ontologie

L'ontologie `sign_language_ontology.owl` a été développée avec Protégé. Elle est utilisée en post-traitement : le label prédit par le modèle est relié à un individu de la classe Sign, dont les propriétés phonologiques sont extraites par recherche directe de triplets RDF, sans raisonneur ni règles d'inférence (section 4.3.1).

D.1.1 Hiérarchie des classes

La hiérarchie principale est la suivante : Thing → Sign | Concept | PhonologicalFeature, où PhonologicalFeature → Handshape | Movement | Location | FacialExpression.

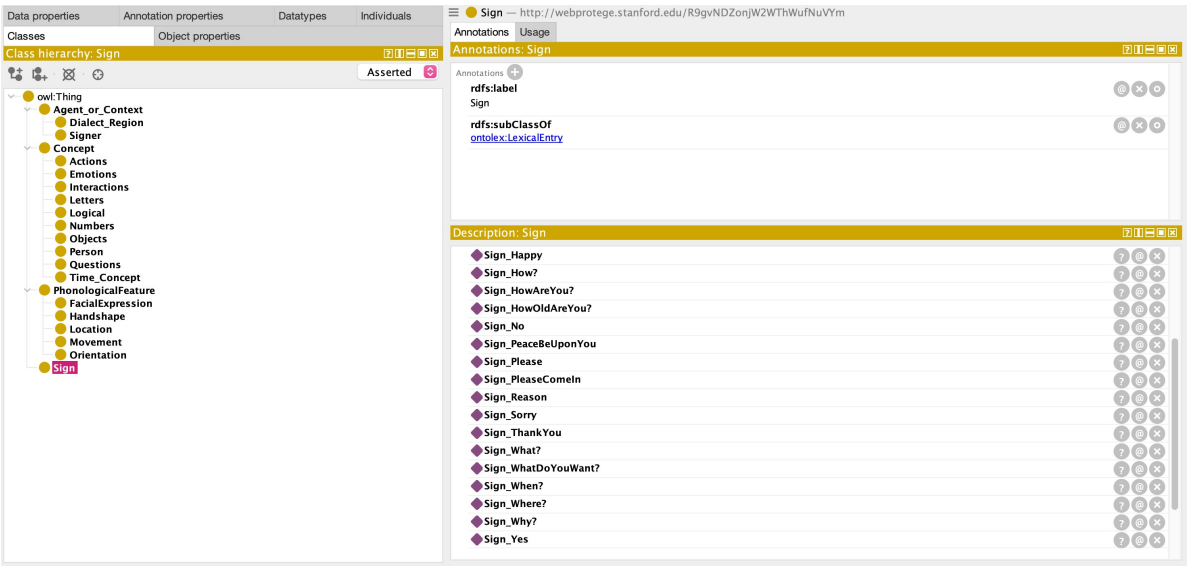


Fig. D.1 : Hiérarchie des classes de l'ontologie dans Protégé.

D.1.2 Propriétés

- **Object Properties :** hasHandshape, hasMovement, hasLocation, hasOrientation, hasFacialExpression, hasHeadMovement, hasBodyPosture, representsConcept.

- **Propriétés de composition :** isCompound, isTwoHanded.

D.1.3 Exemple d'individu : Sign_ThankYou

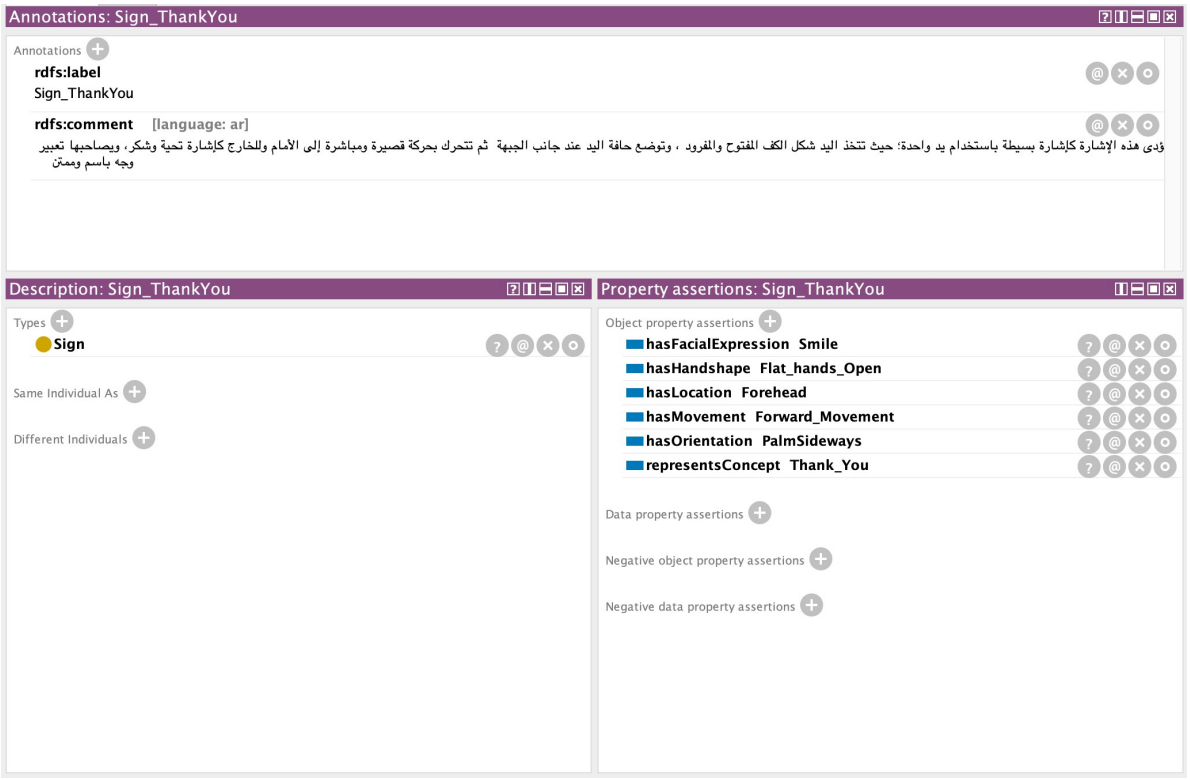


FIG. D.2 : Assertions de propriétés de l'individu Sign_ThankYou dans Protégé.

Annexe E

Article soumis ou publié (le cas échéant)

Référence de l'article (voir aussi la section « Publications scientifiques » des contributions hors stage) :

M. S. M. El Bechir, O. M. A. Deddah, C. A. A. Telmoud, M. C. Tourad et M. F. Nanne, *Towards Semantic Recognition of Arabic Sign Language : Multimodal Fusion and Ontological Structuring*, International Conference I2COMSAPP'26, 2026.

Cet article a été accepté pour présentation à la conférence et pour inclusion dans les actes ; la version finale (prête à imprimer) a été remise au comité de programme (voir la notification d'acceptation en Annexe F). Le texte intégral est disponible sur demande auprès de l'auteur.

Annexe F

Preuves des contributions hors stage


الجمهورية الإسلامية الموريتانية
République Islamique de Mauritanie
وزارة التعليم العالي والبحث العلمي
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
جامعة نواكشوط
Université de Nouakchott
المدرسة الصيفية للنماذج اللغوية الكبيرة واللغات الوطنية
ÉCOLE D'ÉTÉ LLM ET LANGUES NATIONALES
شهادة مشاركة
ATTESTATION DE PARTICIPATION
L'Université de Nouakchott atteste que :
تشهد جامعة نواكشوط بأن:
Mekfoule Sidi Moctar Elbechir
a participé à la 1ère édition de l'École d'été LLMs et langues nationales, consacrée aux grands modèles de langage (LLMs) appliqués aux langues mauritaniennes peu dotées du 23 au 30 août 2026 à Nouadhibou.
La présente attestation est délivrée pour servir et valoir ce que de droit.
قد شارك(ت) في النسخة الأولى من المدرسة الصيفية للنماذج اللغوية الكبيرة (LLMs) واللغات الوطنية، المخصّصة لتطبيق النماذج اللغوية الكبيرة على اللغات الموريتانية محدودة الموارد، وذلك في الفترة من 23 إلى 30 أغسطس 2026 بمدينة نواذيبو.
وقد سُلّمت هذه الشهادة للمعني(ة) بالأمر للاستظهار بها عند الاقتضاء.
Avec l'appui de :
بدعم من :
coopération allemande
Mise en œuvre par :
giz
رئيس جامعة نواكشوط
Président de l'Université de Nouakchott
UNIVERSITÉ DE NOUAKCHOTT

Fig. F.1 : Attestation de participation à l'École d'été LLMs et langues nationales (Nouadhibou, 23–30 août 2026).

Notification d'acceptation de l'article

Extrait traduit du courriel du comité de programme d'I2COMSAPP'26 :

> *Nous avons le plaisir de vous informer que votre article n° 91, « Towards Semantic Recognition of Arabic Sign Language : Multimodal Fusion and Ontological Structuring », a été* ***ACCEPTÉ*** *pour présentation à I2COMSAPP'26 et pour inclusion dans les actes de la conférence, sous réserve de la préparation de la version finale prête à imprimer.*

La version finale a depuis été remise au comité de programme.